

NHẬN DIỆN THỦ NGỮ TIẾNG VIỆT

Sinh viên thực hiện:

1. Nguyễn Tấn Phát - 200123646
2. Nguyễn Thị Thúy Lành - 2001230428
3. Nguyễn Thành Tài - 2001230772
4. Trương Hoàng Thời - 2001230942

GVHD: TS. Phùng Thế Bảo
Nhóm 3



NỘI DUNG

1. MÔ TẢ BÀI TOÁN

2. CƠ SỞ LÝ THUYẾT

3. PHƯƠNG PHÁP ĐỀ XUẤT

4. ĐÁNH GIÁ MÔ HÌNH

5. THỰC NGHIỆM

6. DEMO

MÔ TẢ BÀI TOÁN

- Mục tiêu: Ứng dụng AI và Thị giác máy tính để tự động dịch cử chỉ thủ ngữ tiếng Việt (VSL) thành văn bản hoặc giọng nói.
- Đầu vào: Video, chuỗi hình ảnh (frames), hoặc dữ liệu camera chiều sâu ghi lại hành động ra dấu.
- Đầu ra:
 - Nhận diện từ đơn: Dịch ra một từ vựng tĩnh (VD: "Xin chào").
 - Nhận diện câu liên tục: Dịch chuỗi cử chỉ thành một câu hoàn chỉnh, đúng ngữ pháp.





TRÍCH XUẤT HÌNH THỂ VỚI MEDIAPIPE HOLISTIC

Khái niệm MediaPipe Holistic

- Mô hình thị giác máy tính giải pháp tối ưu hóa luồng trích xuất đồng thời cấu trúc hình thể người theo thời gian thực do Google phát triển.
- Phiên bản Holistic kết hợp thông minh các mô hình mạng nơ-ron chuyên biệt (Pose, Hands và Face Mesh) vào một luồng tính toán đồng nhất giúp mô hình tập trung vào hành động.

Ý tưởng MediaPipe Holistic

- Ý tưởng cốt lõi là thay vì sử dụng toàn bộ ảnh RGB, hệ thống chỉ giữ lại tọa độ các điểm mốc quan trọng.
- Dữ liệu đầu vào
 - Video:

$$V = \{F_1, F_2, \dots, F_T\}$$

Sau khi xử lý: Mỗi frame được chuyển thành tập hợp landmark:

$$L_t = \{p_1, p_2, \dots, p_n\}$$

Các thành phần trích xuất đặc trưng chính

- Face Mesh (Khuôn mặt): Trích xuất lưới 3D với 468 điểm mốc.
- Hands (Bàn tay): Xác định 21 điểm mốc mỗi tay (từ cổ tay đến đầu ngón tay).
- Pose (Tư thế/Dáng đi): Trích xuất 33 điểm mốc trên toàn cơ thể (vai, khuỷu tay, hông, gối...).

Hoạt động của Mediapipe Holistic

- Giai đoạn 1 (Detection): Sử dụng mạng nơ-ron cực nhẹ BlazePose Detector để định vị nhanh vùng chứa thực thể người trong ảnh và thiết lập hộp giới hạn (Bounding Box) làm vùng quan tâm (ROI).
- Giai đoạn 2 (Tracking): Từ vùng ROI tổng thể, mô hình thực hiện cắt ảnh và đưa vào các mạng hồi quy cực bộ chuyên biệt để định vị chính xác tọa độ 3D của các điểm neo.



MẠNG TÍCH CHẬP ĐỒ THỊ KHÔNG - THỜI GIAN (ST - GCN)

Khái niệm

Mạng tích chập đồ thị Không - Thời gian (Spatio-Temporal Graph Convolutional Networks - ST-GCN) là bước tiến vượt bậc trong việc phân tích dữ liệu dạng khung xương người. Khác với các CNN truyền thống coi chuỗi tọa độ là các vector phẳng, ST-GCN mô hình hóa cấu trúc xương cơ thể dưới dạng một đồ thị động không - thời gian $G = (V, E)$.

Biểu diễn đồ thị không - thời gian

Một chuỗi khung xương được biểu diễn bởi đồ thị không-thời gian:

$$G = (V, E)$$

- Tập đỉnh V : Chứa toàn bộ các khớp xương cơ thể qua các khung hình liên tiếp.
- Tập đỉnh E : Gồm các liên kết vật lý không gian tự nhiên của cơ thể người trong cùng một khung hình (E_S) và các liên kết nối liền một khớp xương cụ thể qua các khung hình liên tiếp theo trục thời gian (E_T).

Self-Attention

Self-Attention cho phép mô hình đánh giá mối quan hệ giữa một phần tử với tất cả các phần tử khác trong cùng chuỗi dữ liệu.

Mỗi vector đầu vào được ánh xạ thành ba vector:

- Query (Q): phần tử đang được xem xét.
- Key (K): đặc trưng dùng để đối sánh với Query.
- Value (V): chứa thông tin nội dung thực tế.

Các vector Q, K, V được tạo ra bằng cách nhân dữ liệu đầu vào với các ma trận trọng số học được W_Q , W_K và W_V .

Dựa trên mức độ tương đồng giữa Query và Key, mô hình tính trọng số chú ý để tổng hợp thông tin từ Value, giúp biểu diễn ngữ cảnh hiệu quả hơn.

Self-Attention

Cơ chế hoạt động

- Mức độ liên quan giữa các phần tử được xác định bằng tích vô hướng giữa Query và Key: QK^T
- Kết quả được chuẩn hóa bằng căn bậc hai số chiều của vector Key để tránh giá trị quá lớn: $\sqrt{d_k}$
- Điểm chú ý cuối cùng được tính theo công thức:

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- Các bước thực hiện:
 - Tính ma trận tương đồng QK^T .
 - Chia cho $\sqrt{d_k}$ để ổn định giá trị.
 - Áp dụng Softmax để tạo phân phối xác suất.
 - Nhân với V để tạo đầu ra cuối cùng.
 - Từ khóa để nhớ nhanh khi thuyết trình:
- $QK^T \rightarrow \div \sqrt{d_k} \rightarrow Softmax \rightarrow \times V \rightarrow Output$.

Multi-Head Self-Attention

Transformer sử dụng nhiều Attention Heads thay vì một Attention duy nhất.

Mỗi head học một loại quan hệ khác nhau:

- Head 1: Quan hệ vị trí
- Head 2: Quan hệ ngữ nghĩa
- Head 3: Quan hệ chuyển động
- Head 4: Quan hệ thời gian dài hạn

Công thức tính từng Head:

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$$

Ghép các Head lại:

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O$$

Mạng Transformer Encoder

Là thành phần mã hóa của kiến trúc Transformer.

Nhiệm vụ:

- Chuyển đổi chuỗi đầu vào thành biểu diễn đặc trưng có ngữ nghĩa cao.
- Phục vụ cho bài toán phân loại và dự đoán.

Kiến trúc Encoder Layer

Thành phần	Chức năng
Multi-Head Self-Attention	Học mối quan hệ giữa các phần tử trong chuỗi dữ liệu. Khai thác thông tin ngữ cảnh và sự phụ thuộc dài hạn. Đầu vào: Chuỗi vector đặc trưng. Đầu ra: Biểu diễn ngữ cảnh đã được tăng cường.
Feed Forward Network (FFN)	Mạng MLP hai tầng áp dụng cho từng vector. Lớp 1: Mở rộng số chiều đặc trưng. ReLU: Tạo tính phi tuyến. Lớp 2: Đưa dữ liệu về kích thước ban đầu.

Mạng Transformer Encoder

Kiến trúc Encoder Layer

Công thức FFN

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Trong đó:

- Lớp đầu mở rộng số chiều.
- Hàm ReLU tạo tính phi tuyến.
- Lớp thứ hai đưa dữ liệu về kích thước ban đầu.

Layer Normalization and Positional Encoding

Thành phần	Vai trò
Residual Connection	-Kết nối tắt giữa đầu vào và đầu ra của tầng mạng. -Giữ lại thông tin gốc. -Giảm hiện tượng tiêu biến gradient. -Tăng tốc độ hội tụ khi huấn luyện
Layer Normalization	-Chuẩn hóa dữ liệu sau mỗi Residual Connection. -Ổn định phân phối dữ liệu. -Tăng tốc độ huấn luyện. -Cải thiện khả năng tổng quát hóa của mô hình.

Residual Connection:

$$Y = X + \textit{Sublayer}(X)$$

Layer Normalization:

$$\textit{Layer Norm}(x)$$

Positional Encoding


Nội dung	Mô tả
Vấn đề	Transformer xử lý song song nên không tự nhận biết được thứ tự dữ liệu.
Giải pháp	Bổ sung Positional Encoding bằng các hàm sin và cos vào vector đầu vào.
Vai trò	Giúp mô hình nhận biết vị trí và thứ tự xuất hiện của các phần tử trong chuỗi.
Ứng dụng trong thủ ngữ	Phân biệt thứ tự chuyển động, sự thay đổi tư thế theo thời gian và các động tác có hình dạng giống nhau nhưng trình tự khác nhau.

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d}}\right)$$

Vai trò trong đề tài

- Self-Attention giúp mô hình xác định mức độ quan trọng của từng frame trong chuỗi thủ ngữ.
- Transformer Encoder khai thác quan hệ dài hạn và ngữ cảnh toàn cục giữa các frame để tạo biểu diễn đặc trưng mạnh hơn.
- Kết hợp với MediaPipe để trích xuất landmarks và ST-GCN để học đặc trưng không-thời gian.
- Giúp mô hình nắm bắt tốt sự thay đổi chuyển động theo thời gian.
- Nâng cao độ chính xác nhận diện thủ ngữ tiếng Việt, đặc biệt với các ký hiệu phức tạp và kéo dài nhiều khung hình.





Rule-based NLP Translator


Giới thiệu

Rule-based NLP Translator là phương pháp dịch dựa trên từ điển ánh xạ và các quy tắc ngôn ngữ được xây dựng thủ công. Trong hệ thống nhận diện thủ ngữ, phương pháp này được sử dụng để chuyển đổi các nhãn thủ ngữ đã nhận dạng thành câu tiếng Việt tự nhiên, giúp văn bản đầu ra đúng ngữ nghĩa và dễ hiểu hơn.

Nội dung	Mô tả
Khái niệm	Hệ thống dịch dựa trên tập luật được xây dựng thủ công thay vì học từ dữ liệu.
Thành phần	Từ điển ánh xạ, quy tắc ngữ pháp, luật chuyển đổi cú pháp và ngữ nghĩa.
Chức năng	Chuyển đổi kết quả nhận dạng thành câu tiếng Việt tự nhiên và có nghĩa.
Đặc điểm	Dễ kiểm soát đầu ra, không cần huấn luyện mô hình.

Ý tưởng hoạt động


VÍ DỤ HOẠT ĐỘNG CỦA RULE-BASED TRANSLATOR TRONG NHẬN DIỆN THỦ NGỮ



Giải thích:


- Ngôn ngữ ký hiệu có thể khác trật tự từ so với tiếng Việt.
- Rule-based Translator không chỉ ghép từ đơn thuần mà còn:
 - ✓ Điều chỉnh trật tự từ
 - ✓ Bổ sung từ/cụm từ cần thiết
 - ✓ Đảm bảo câu tự nhiên và đúng ngữ nghĩa

Pipeline tổng quát



Vai trò trong đề tài


- Rule-based NLP Translator là tầng hậu xử lý cuối cùng của hệ thống.
- Tiếp nhận các nhân thủ ngữ đã được nhận diện bởi MediaPipe Holistic → ST-GCN → Transformer Encoder.
- Ánh xạ các nhân thành từ tiếng Việt và áp dụng các quy tắc ngữ pháp, cú pháp để tạo câu hoàn chỉnh.
- Giúp văn bản đầu ra tự nhiên, dễ hiểu và đúng ngữ nghĩa hơn.
- Phù hợp với các bộ dữ liệu thủ ngữ có từ vựng và cấu trúc câu còn hạn chế, không cần huấn luyện thêm mô hình ngôn ngữ lớn.





PHƯƠNG PHÁP ĐỀ XUẤT TRIỂN KHAI

Pipeline triển khai dự án diễn ra như sau



Tiền xử lý dữ liệu

Trích xuất và giữ lại hệ tọa độ không gian ba chiều (x, y, z) của 67 điểm khớp

Bàn Tay Trái (21 Điểm)

Chi tiết cấu trúc các khớp ngón, độ dài, hình học lòng bàn tay.





Bàn Tay Phải (21 Điểm)

Bắt trọn các vi biểu cảm, độ uốn cong của ngón tay.



Tư Thế Cơ Thể (25 Điểm)

Tính toán độ xoay vai, cúi chỏ, đống vai trở làm trục tọa độ gốc (Dời trung điểm về hai vai).



Tiền xử lý dữ liệu


Cắt bỏ khung hình tĩnh (Motion Trimming)



Tiền xử lý dữ liệu

Chuẩn hóa không gian tọa độ:

1. Tịnh tiến tọa độ về gốc trung tâm nối 2 vai
2. Co giãn kích thước dựa trên khoảng cách vật lý giữa 2 vai.



Áp dụng kỹ thuật tăng cường dữ liệu




Cắt ngẫu nhiên 80-100% thời lượng và nội suy tuyến



Bóp méo thời gian ,mô phỏng nhịp điệu nhanh/chậm



Thêm nhiễu $N(0, 0.005^2)$ mô phỏng độ rung lắc



Thêm nhiễu $N(0, 0.005^2)$ mô phỏng độ rung lắc




Nhiều lớn ở ngón tay, nhiều nhỏ ở thân người




Zero hóa 1-2 khớp ngẫu nhiên, huấn luyện mạng chịu lỗi

Trích xuất đặc trưng đa luồng



Đặc tả cấu trúc VSTGCN





THỰC NGHIỆM VÀ TRIỂN KHAI WEB

Môi trường thực hiện

	Local PC: Suy diễn & Triển khai
• Hệ điều hành	Windows 11
• Bộ vi xử lý:	Intel Core i5-1035G1
• Bộ nhớ:	16GB RAM
• Đồ họa:	Intel UHD Graphics (Tích hợp)
• Vai trò cốt lõi: Xử lý WebSockets thời gian thực, trích xuất MediaPipe Holistic (độ trễ ~4.2ms) và chạy mô hình suy diễn (Inference) cục bộ qua Webcam.	

	Google Colab: Huấn luyện Mô hình
• Hệ điều hành	Ubuntu
• Bộ vi xử lý:	Intel Xeon 2.20Hz
• Bộ nhớ:	13GB RAM
• Đồ họa:	NVIDIA T4 GPU (16GB VRAM)
• Vai trò cốt lõi: Gánh vác khối lượng tính toán đồ thị không-thời gian (ST-GCN) khổng lồ, xử lý hàng ngàn video với Batch Size 32.	

Thu thập dữ liệu




Cấu hình huấn luyện trên colab GPU T4

Phân chia Dữ liệu (Data Split)



80% Train | 10% Val | 10% Test.
Áp dụng Stratified Split bảo
toàn phân bố nhãn đều.


Tài nguyên & Vòng lặp



Batch Size: 32 (Tối ưu hóa bộ
nhớ 16GB VRAM).


Epochs: 80 (Tích hợp Early Stopping
min_delta=1e-4 tại 12 epochs).

Điều phối Tốc độ (Scheduler)




OneCycleLR: Tăng tốc độ học lên cực đại ở 30%
chặng đầu, sau đó giảm dần (Cosine Decay) để
tránh bẫy cực tiểu địa phương.

Thuật toán Tối ưu




Optimizer: AdamW.




Tách biệt Weight Decay (1e-4) giúp
cập nhật độ dốc gradient ổn định
và chống co giãn trọng số.

Kết quả thực nghiệm

Biểu đồ Loss qua các Epochs (Độ lỗi)



Biểu đồ Accuracy trên tập Validation



Triển khai giao diện web

VSL AI Translator



Từ nhận diện

Confidence

0.3705

Câu dịch

Xin chào tất cả mọi người!

Bộ đệm

0

Tiến trình nhận diện

35/60 Frames (Đang thu thập...)




Triển khai giao diện web

Upload Video

Choose File toitenhieu.mp4

Nhận Diện Video

Triển khai giao diện web



Phân tích độ trễ khi triển khai trên web



MediaPipe trích xuất

~4.2 ms

VSTGCN suy diễn

~12.5 ms

NLP Translator

< 0.1 ms

Tổng độ trễ

~18.0 ms

Hệ thống đạt 25 - 30 FPS qua giao thức Socket.I.O.
Hoạt động mượt trên trình duyệt



THANK YOU