

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP. HCM
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN HỌC PHẦN HỌC SÂU

NHẬN DIỆN THỦ NGỮ TIẾNG VIỆT

Ngành: Công nghệ thông tin

SINH VIÊN THỰC HIỆN:

1. 2001230646 – Nguyễn Tấn Phát – 14DHTH07
2. 2001230428 – Nguyễn Thị Thúy Lành – 14DHTH12
3. 2001230772 – Nguyễn Thành Tài – 14DHTH13
4. 2001230942 – Trương Hoàng Thời – 14DHTH15

TP. HỒ CHÍ MINH, tháng 6 năm 2026

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP. HCM
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN HỌC PHẦN HỌC SÂU

NHẬN DIỆN THỦ NGỮ TIẾNG VIỆT

Ngành: Công nghệ thông tin

GIẢNG VIÊN HƯỚNG DẪN: TS. Phùng Thế Bảo

SINH VIÊN THỰC HIỆN:

1. 2001230646 – Nguyễn Tấn Phát – 14DHTH07
2. 2001230428 – Nguyễn Thị Thúy Lành – 14DHTH12
3. 2001230772 – Nguyễn Thành Tài – 14DHTH13
4. 2001230942 – Trương Hoàng Thời – 14DHTH15

TP. HỒ CHÍ MINH, tháng 6 năm 2026

LỜI CẢM ƠN

Trước hết, nhóm chúng em xin chân thành cảm ơn giáo viên hướng dẫn đã tận tình giảng dạy, hướng dẫn và đóng góp nhiều ý kiến quý báu trong suốt quá trình học tập và thực hiện tiểu luận. Sự hỗ trợ và định hướng của thầy đã giúp nhóm hoàn thành đồ án đúng yêu cầu môn học.

Nhóm đã dành nhiều thời gian, tâm huyết và nỗ lực để hoàn thiện đề tài một cách trọn vẹn nhất, song do giới hạn về mặt thời gian, kinh nghiệm nghiên cứu cũng như cơ sở dữ liệu thực nghiệm, cuốn báo cáo chắc chắn không tránh khỏi những thiếu sót và hạn chế nhất định. Nhóm chúng em rất mong nhận được những ý kiến đóng góp, phê bình quý báu từ thầy và các bạn sinh viên để đề tài ngày càng được hoàn thiện và có thể phát triển ứng dụng sâu rộng hơn trong thực tiễn.

Nhóm chúng em xin chân thành cảm ơn!

Nhóm sinh viên thực hiện đồ án

(Ký và ghi rõ họ tên)

Nguyễn Tấn Phát

Nguyễn Thị Thúy Lành

Nguyễn Thành Tài

Trương Hoàng Thời

MỤC LỤC

LỜI CẢM ƠN	i
MỤC LỤC.....	ii
BẢNG PHÂN CÔNG NHIỆM VỤ	v
DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT	vi
DANH MỤC HÌNH	viii
DANH MỤC BẢNG.....	ix
MỞ ĐẦU.....	1
CHƯƠNG 1: TỔNG QUAN.....	2
1. ĐẶT VẤN ĐỀ	2
2. LÝ DO CHỌN ĐỀ TÀI.....	2
3. TỔNG QUAN CÁC QUÁ TRÌNH NGHIÊN CỨU	3
4. TÍNH MỚI VÀ ĐÓNG GÓP CỦA ĐỒ ÁN.....	3
5. MỤC TIÊU NGHIÊN CỨU	4
6. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU	4
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	5
2.1. NGÔN NGỮ KÝ HIỆU VÀ BÀI TOÁN NHẬN DIỆN.....	5
2.2. TRÍCH XUẤT HÌNH THỂ VỚI MEDIAPIPE HOLISTIC.....	6
2.2.1. Giới thiệu.....	6
2.2.2. Khái niệm MediaPipe Holistic	7
2.2.3. Các thành phần trích xuất đặc trưng chính.....	7
2.2.4. Ý tưởng của Mediapipe Holistic	8
2.2.5. Hoạt động của Mediapipe Holistic.....	9
2.2.6. Vai trò trong đề tài nhận diện thủ ngữ tiếng Việt.....	10
2.3. MẠNG TÍCH CHẬP ĐỒ THỊ KHÔNG-THỜI GIAN (ST-GCN).....	10
2.3.1. Giới thiệu.....	10
2.3.2. Khái niệm	11
2.3.3. Biểu diễn đồ thị không – thời gian	11
2.3.4. Phép tích chập đồ thị không gian (Spatial Graph Convolution)	12
2.3.5. Phép tích chập đồ thị thời gian	13
2.3.6. Vai trò của ST-GCN trong bài toán nhận diện thủ ngữ tiếng Việt	13
2.4. CƠ CHẾ TỰ CHÚ Ý (SELF-ATTENTION) VÀ MẠNG TRANSFORMER ENCODER.....	14

2.4.1. Cơ chế tự chú ý (self-attention).....	14
2.4.1.1. Giới thiệu.....	14
2.4.1.2. Ý tưởng cơ bản.....	14
2.4.1.3. Cơ chế hoạt động.....	15
2.4.1.4. Multi-Head Self-Attention	16
2.4.2. Mạng Transformer Encoder	16
2.4.2.1. Giới thiệu.....	16
2.4.2.2. Kiến trúc Transformer Encoder.....	16
2.4.2.3. Residual Connection.....	17
2.4.2.4. Layer Normalization.....	17
2.4.2.5. Positional Encoding.....	18
2.4.3. Vai trò của Self-Attention và Transformer Encoder trong đề tài Nhận diện Thủ ngữ Tiếng Việt	18
2.5. RULE-BASED NLP TRANSLATOR (BỘ DỊCH NGÔN NGỮ TỰ NHIÊN DỰA TRÊN LUẬT).....	18
2.5.1. Giới thiệu.....	19
2.5.2. Khái niệm	19
2.5.3. Ý tưởng hoạt động.....	19
2.5.4. Vai trò trong đề tài nhận diện thủ ngữ tiếng Việt.....	19
CHƯƠNG 3: PHƯƠNG PHÁP ĐỀ XUẤT TRIỂN KHAI.....	21
3.1. TIỀN XỬ LÝ DỮ LIỆU VÀ CHUẨN HÓA KHÔNG GIAN	21
3.1.1. Trích xuất đặc trưng và điền khuyết.....	21
3.1.2. Cắt bỏ khung hình tĩnh (Motion Trimming):	21
3.1.3. Chuẩn hóa không gian tọa độ (Spatial Normalization).....	22
3.2. CÁC KỸ THUẬT TĂNG CƯỜNG DỮ LIỆU	22
3.3. HỆ THỐNG TRÍCH XUẤT ĐẶC TRƯNG ĐA LUỒNG (MULTI-STREAM FEATURE ENGINEERING).....	23
3.4. XÂY DỰNG KIẾN TRÚC MÔ HÌNH VSTGCN	24
3.5. BỘ DỊCH THUẬT CÚ PHÁP THEO QUY TẮC NGOẠI TUYẾN (RULE-BASED NLP TRANSLATOR).....	30
CHƯƠNG 4: THỰC NGHIỆM VÀ XÂY DỰNG WEBSITE	31
4.1. MÔI TRƯỜNG VÀ CÔNG CỤ THỰC NGHIỆM.....	31

4.2. THU THẬP DỮ LIỆU.....	31
4.3. THAM SỔ HUẤN LUYỆN	33
4.4. KẾT QUẢ THỰC NGHIỆM.....	34
4.5. TRIỂN KHAI WEBSITE	36
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	40
1. CÁC KẾT QUẢ ĐẠT ĐƯỢC CỦA ĐỒ ÁN.....	40
2. CÁC HẠN CHẾ CÒN TỒN TẠI.....	40
3. HƯỚNG NGHIÊN CỨU VÀ PHÁT TRIỂN TRONG TƯƠNG LAI.....	40
TÀI LIỆU THAM KHẢO.....	42

BẢNG PHÂN CÔNG NHIỆM VỤ

MSSV	Họ và tên	Nhiệm vụ	Hoàn thành
2001230646	Nguyễn Tấn Phát	- Xây dựng và huấn luyện mô hình - Thực nghiệm đánh giá mô hình và triển khai website - Word - Powerpoint	100%
2001230428	Nguyễn Thị Thúy Lành	- Tìm hiểu Mediapipe Holistic và ST-GCN - Thực hiện kỹ thuật tiền xử lý dữ liệu - Word - Powerpoint	100%
2001230772	Nguyễn Thành Tài	- Tìm hiểu Transformer Encoder và RULE-BASED NLP - Thực hiện kỹ thuật tăng cường dữ liệu - Word - Powerpoint	100%
2001230942	Trương Hoàng Thời	- Thu thập dữ liệu - Tìm phương pháp xây dựng mô hình - Word - Powerpoint	100%

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Viết tắt	Tiếng Anh	Tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
CPU	Central Processing Unit	Bộ xử lý trung tâm
CSLR	Continuous Sign Language Recognition	Nhận diện ngôn ngữ ký hiệu liên tục
FPS	Frames Per Second	Số khung hình trên giây
GCN	Graph Convolutional Network	Mạng tích chập đồ thị
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
LR	Learning Rate	Tốc độ học (Hệ số học tập)
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
RGB	Red-Green-Blue	Không gian màu Đỏ - Xanh lá - Xanh dương
ROI	Region of Interest	Vùng quan tâm cục bộ của ảnh
SLR	Sign Language Recognition	Nhận diện ngôn ngữ ký hiệu
SOTA	State-Of-The-Art	Tiên tiến nhất / Công nghệ hiện đại nhất
ST-GCN	Spatio-Temporal Graph Convolutional Network	Mạng tích chập đồ thị Không-Thời gian
TCN	Temporal Convolutional Network	Mạng tích chập thời gian
VRAM	Video Random Access Memory	Bộ nhớ truy cập ngẫu nhiên đồ họa
VSL	Vietnamese Sign Language	Ngôn ngữ Ký hiệu Việt Nam

VSTGCN	Video Spatial-Temporal Graph Convolutional Network	Mạng tích chập đồ thị Không-Thời gian Video
$G = (V, E)$	Graph with Vertices and Edges	Đồ thị gồm tập các đỉnh (V) và tập các cạnh (E)
A	Adjacency Matrix	Ma trận kề biểu diễn liên kết xương cơ thể
$\hat{A}$	Normalized Adjacency Matrix	Ma trận kề đã chuẩn hóa đối xứng
D	Degree Matrix	Ma trận bậc của đồ thị
Q, K, V	Query, Key, Value Matrices	Các ma trận Truy vấn, Khóa, Giá trị trong cơ chế Attention
PE	Positional Encoding	Mã hóa vị trí lượng giác thời gian

DANH MỤC HÌNH

Hình 1. Giới thiệu ngôn ngữ ký hiệu Việt Nam	5
Hình 2. Giới thiệu Mediapipe Holistic.....	7
Hình 3. Sơ đồ 21 điểm bàn tay của Mediapipe Hands.....	8
Hình 4. Sơ đồ 33 điểm Pose Landmarks của MediaPipe Pose	8
Hình 5. Giới thiệu về ST-GCN.....	10
Hình 6. Hàm lấp đầy khoảng trống bằng thuật toán ffill/bfill.....	21
Hình 7. Trang web QIPEDC về tài liệu ngôn ngữ ký hiệu	32
Hình 8. Video thu thập từ nhóm.....	32
Hình 9. Biểu đồ loss và top-accuracy.....	34
Hình 10. Giao diện nhận diện ký tự đơn lẻ dịch thành câu qua webcam	37
Hình 11. Giao diện cho phép người dùng tra từ điển ký hiệu xem video	38
Hình 12. Giao diện cho phép người dùng tải video lên và nhận diện câu	38

DANH MỤC BẢNG

Bảng 1. Mô tả các lớp và thông số của từng thành phần trong mạng.....	25
Bảng 2. Mô tả tham số huấn luyện của mô hình.....	34
Bảng 3. Bảng đánh giá loss và top-accuracy	36
Bảng 4. Bảng đánh giá hiệu năng của web khi nhận diện câu.....	39

MỞ ĐẦU

Trong bối cảnh thế giới đang dịch chuyển mạnh mẽ sang kỷ nguyên số và trí tuệ nhân tạo, công nghệ không chỉ đóng vai trò tối ưu hóa hiệu suất lao động mà còn mang sứ mệnh nhân văn cao cả: kết nối con người và thúc đẩy sự bình đẳng trong xã hội. Một trong những rào cản lớn nhất đối với sự hòa nhập của cộng đồng người khiếm thính hiện nay chính là sự bất đồng về ngôn ngữ. Ngôn ngữ ký hiệu (thủ ngữ) dù là một hệ thống giao tiếp hoàn chỉnh, sinh động nhưng lại chưa thực sự phổ biến đối với đại đa số đại chúng.

Chính từ thực tiễn đó, cùng sự phát triển mạnh mẽ của Trí tuệ Nhân tạo (AI) và Thị giác Máy tính (Computer Vision). Với mong muốn ứng dụng những thành tựu công nghệ mới nhất để thu hẹp khoảng cách giao tiếp này, nhóm chúng em đã quyết định lựa chọn và thực hiện đề tài đồ án học sâu: "Nhận diện Thủ ngữ tiếng Việt".

Cuốn báo cáo này là kết quả của quá trình nghiên cứu lý thuyết nghiêm túc, khảo sát thực trạng và thực nghiệm xây dựng hệ thống. Nội dung của đề tài tập trung vào việc tối ưu hóa pipeline trích xuất dữ liệu khung xương động thông qua thư viện MediaPipe Holistic, giải quyết bài toán thiếu hụt dữ liệu bằng các thuật toán tăng cường không - thời gian và đề xuất một kiến trúc mạng lai hợp tiên tiến giữa Mạng tích chập đồ thị (ST-GCN) với Transformer Encoder nhằm bắt trọn các đặc trưng tinh tế nhất của thủ ngữ Việt Nam.

CHƯƠNG 1: TỔNG QUAN

1. ĐẶT VẤN ĐỀ

Mặc dù các mô hình nhận dạng hành động và ngôn ngữ ký hiệu (SLR) đã được nghiên cứu rộng rãi trên thế giới, việc xây dựng một giải pháp hoàn chỉnh cho Ngôn ngữ Ký hiệu Việt Nam (VSL) vẫn đang đối mặt với những thách thức mang tính cốt lõi:

- **Đặc thù ngôn ngữ học tự nhiên:** VSL sở hữu hệ thống từ vựng, cú pháp độc lập, không tuân theo trật tự tuyến tính của ngữ pháp tiếng Việt nói thông thường. Người biểu diễn ký hiệu thường tối giản hóa các giới từ, liên từ.
- **Hạn chế về công nghệ và tính ứng dụng thực tế:** Các nghiên cứu truyền thống thường đòi hỏi thiết bị thu nhận chuyên dụng đắt tiền (găng tay cảm biến, camera chiều sâu Kinect) hoặc các mô hình học sâu quá nặng nề (mã hóa video thô 3D-CNN) không thể triển khai chạy mượt mà trên các thiết bị phổ thông hay môi trường trình duyệt web theo thời gian thực (real-time).
- **Thách thức dữ liệu cực nhỏ (Small Dataset Problem):** Việc thu thập và gán nhãn chuẩn hóa dữ liệu video ngôn ngữ ký hiệu yêu cầu trình độ chuyên môn cao và chi phí cực lớn. Bộ dữ liệu VSL hiện nay có số lượng mẫu rất hạn chế trên mỗi lớp từ vựng. Khi huấn luyện các mô hình học sâu có dung lượng lớn, hiện tượng học vẹt (Overfitting) xảy ra rất sớm, khiến mô hình mất đi tính tổng quát hóa trên dữ liệu thực tế.

2. LÝ DO CHỌN ĐỀ TÀI

Nhằm giải quyết triệt để các nút thắt trên, đề tài "**Nhận diện Thủ ngữ tiếng Việt**" được lựa chọn nghiên cứu và triển khai với các lý do khoa học và thực tiễn sau:

- **Giá trị nhân văn và thực tiễn:** Tạo ra một nền tảng phần mềm gọn nhẹ, có khả năng vận hành trực tiếp thông qua các dòng Webcam phổ thông tích hợp sẵn trên máy tính, giúp biên dịch trực tiếp cử chỉ tay thành câu tiếng Việt hoàn chỉnh, hỗ trợ đắc lực cho người khiếm thính hòa nhập xã hội.
- **Sự tiên tiến và tối ưu hóa về mặt công nghệ:** Đề tài ứng dụng giải pháp lai hợp đột phá giữa trích xuất khung xương động (Skeleton-based) bằng

MediaPipe và kiến trúc đồ thị học sâu cải tiến VSTGCN. Sự kết hợp này loại bỏ hoàn toàn các luồng xử lý đồ họa công kênh, giảm tải tối đa năng lượng tính toán trên CPU/GPU mà vẫn duy trì độ chính xác cực cao.

- **Làm chủ dịch thuật ngôn ngữ tự nhiên:** Ứng dụng các quy tắc ngữ pháp ánh xạ thủ công (Rule-based NLP) thông minh, giúp hệ thống dịch thuật hoạt động hoàn toàn ngoại tuyến (offline 100%), đạt độ trễ tiệm cận 0 ms, bảo mật thông tin tuyệt đối và kiểm soát hoàn toàn đầu ra ngôn ngữ, tránh hiện tượng sinh từ sai lệch của các mạng nơ-ron sinh phức tạp.

3. TỔNG QUAN CÁC QUÁ TRÌNH NGHIÊN CỨU

Ngoài nước: Các quốc gia phát triển đã xây dựng các bộ dữ liệu ngôn ngữ ký hiệu quy mô lớn như PHOENIX-Weather (Đức), MS-ASL (Mỹ). Hướng tiếp cận thị giác máy tính đã chuyển dịch mạnh mẽ từ phân tích pixel ảnh màu sang phân tích dữ liệu khung xương khớp (Skeleton-based GCN) nhờ sự ra đời của ST-GCN (Yan et al., 2018). Các nghiên cứu gần đây tập trung tích hợp cơ chế Attention để tăng cường khả năng bám bắt ngữ cảnh thời gian dài của chuỗi ký hiệu.

Trong nước: Nghiên cứu về VSL tại Việt Nam phần lớn vẫn dừng lại ở các phương pháp nhận diện ảnh ký hiệu tĩnh (Static Sign Language), nhận diện bảng chữ cái đơn lẻ hoặc sử dụng các mạng LSTM truyền thống với đặc trưng ảnh thô chứa nhiều nhiễu. Các hệ thống thực tế có khả năng nhận diện ký hiệu động liên tục (Continuous Sign Language), tự động cân bằng mẫu dữ liệu nhỏ và tích hợp dịch thuật hoàn chỉnh thành câu nói tự nhiên chưa thực sự được phát triển một cách bài bản.

4. TÍNH MỚI VÀ ĐÓNG GÓP CỦA ĐỒ ÁN

Đồ án này mang lại những đóng góp khoa học và kỹ thuật mới nổi bật:

- **Bộ tăng cường dữ liệu và cân bằng động (Dynamic Balancer & Augmentation Pipeline):** Thiết kế thành công chuỗi 6 kỹ thuật tăng cường không-thời gian phong phú và bộ điều phối dynamic balancer tự động tính toán, bù đắp mẫu học tập cho các lớp dữ liệu yếu. Giải quyết triệt để bài toán mất cân bằng class và thiếu hụt dữ liệu trên tập mẫu VSL nhỏ.
- **Kiến trúc mạng lai hợp VSTGCN cải tiến:** Đề xuất tầng Spatial Embedding Projection đột phá để trải phẳng và bảo tồn trọn vẹn đặc trưng ngón, khắc phục nhược điểm của phép Pooling không gian truyền thống,

kết hợp sức mạnh phân tích quan hệ cấu trúc xương của ST-GCN và học chuỗi ngữ cảnh thời gian dài của Transformer Encoder.

- **Pipeline hoàn chỉnh và tối ưu hóa thời gian thực:** Triển khai thành công ứng dụng Web hoàn chỉnh hỗ trợ nhận diện trực tiếp qua Webcam bằng Socket.IO, tích hợp công cụ dịch cú pháp ngôn ngữ tự nhiên theo quy tắc (Rule-based NLP Translator) siêu nhẹ chạy offline mượt mà.

5. MỤC TIÊU NGHIÊN CỨU

Nghiên cứu sâu sắc lý thuyết tích chập đồ thị (GCN) trên dữ liệu khung xương cơ thể người và cơ chế Attention trong học máy.

Triển khai bộ tiền xử lý, lọc nhiễu nền, chuẩn hóa không gian tọa độ và bộ tăng cường dữ liệu đa dạng.

Huấn luyện thành công mô hình học sâu lai hợp VSTGCN đạt độ chính xác cao và tối ưu hóa tài nguyên phần cứng.

Xây dựng ứng dụng Web tương tác thời gian thực, tích hợp bộ dịch thuật ngữ pháp tự động và từ điển ký hiệu thông minh phục vụ cộng đồng.

6. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

Đối tượng nghiên cứu: Cấu trúc khung xương chuyển động 3D của người biểu diễn ngôn ngữ ký hiệu Việt Nam, kiến trúc mạng ST-GCN, Transformer Encoder và các quy tắc cú pháp ngôn ngữ ký hiệu VSL.

Phạm vi nghiên cứu: Hệ thống tập trung nhận diện hệ từ vựng ngôn ngữ ký hiệu biệt lập (Isolated Sign Language Recognition) với danh mục lên tới 538 lớp nhãn khác nhau (gồm chữ cái, số đếm, danh từ, động từ, tính từ và các cấu trúc giao tiếp thông dụng) được thu thập và thực nghiệm trong môi trường thời gian thực qua thiết bị camera/webcam tiêu chuẩn.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. NGÔN NGỮ KÝ HIỆU VÀ BÀI TOÁN NHẬN DIỆN

Ngôn ngữ ký hiệu là ngôn ngữ sử dụng hình dạng bàn tay, chuyển động cơ thể, cử chỉ điệu bộ và sự thể hiện trên khuôn mặt để giao tiếp, trao đổi kinh nghiệm, suy nghĩ, nhu cầu và cảm xúc.

Ngôn ngữ ký hiệu (thủ ngữ) là ngôn ngữ của cộng đồng người khiếm thính. Đây là ngôn ngữ bẩm sinh và tự nhiên của người khiếm thính, được cộng đồng người khiếm thính sử dụng rộng rãi. Ngôn ngữ ký hiệu là phương tiện giao tiếp phức tạp và toàn diện như bất cứ ngôn ngữ nói nào. Nó cũng là phương tiện được mã hóa chuyển tải thông tin và được chi phối bởi các quy tắc ngữ pháp. Tuy nhiên, không giống như ngôn ngữ nói, ngôn ngữ ký hiệu không truyền tải thông qua phương tiện truyền âm mà qua phương tiện hình ảnh, còn được gọi là ngôn ngữ thị giác. Ngôn ngữ ký hiệu được “phát âm” bằng cử chỉ được thực hiện bằng tay với những quy tắc nhất định. Các kí hiệu bằng tay được bổ sung thêm và được hỗ trợ bởi các thể hiện trên nét mặt và cử động của cơ thể.



Hình 1. Giới thiệu ngôn ngữ ký hiệu Việt Nam

Những công trình nghiên cứu của các nhà ngôn ngữ học hiện đại, mở đầu là William Stokoe đã phát hiện ra ngôn ngữ kí hiệu, cũng như những ngôn ngữ khác, phải trải qua nhiều thay đổi. Bước đầu họ phát hiện ngôn ngữ kí hiệu có cấu trúc ngữ pháp riêng không giống cấu trúc ngữ pháp của ngôn ngữ nói, nhưng nó có thể chuyển tải được tất cả các khái niệm trừu tượng.

Do đây là phương pháp giao tiếp thông qua khả năng thị giác và di chuyển nên đây chính là ngôn ngữ có thể khắc phục được những hạn chế về khả năng nghe, tận dụng những khả năng vượt trội về thị giác của người khiếm thính.

Ngôn ngữ kí hiệu giúp người khiếm thính thể hiện mọi thông tin, suy nghĩ, cảm xúc đơn giản hay phức tạp, do đó dễ dàng thông hiểu lẫn nhau, dễ truyền thụ kinh nghiệm cho nhau. Có thể nói, ngôn ngữ kí hiệu cũng có thể thực hiện được chức năng giao tiếp hoàn toàn như ngôn ngữ nói. Thông qua đó giúp người điếc phát triển tri thức, nhận thức được những quy tắc cơ bản trong giao tiếp, những kĩ năng cần thiết cho cuộc sống. Do đó, nó không phải là rào cản, mà ngược lại chính là cơ hội để giúp người điếc học và sử dụng ngôn ngữ lời nói như là một ngôn ngữ thứ hai một cách dễ dàng hơn.

Bài toán nghiên cứu của đề tài này là:


Xây dựng hệ thống tự động nhận diện Ngôn ngữ Ký hiệu Việt Nam biệt lập từ luồng video Webcam theo thời gian thực, sau đó tự động biên dịch và tái cấu trúc chuỗi ký hiệu thô thành câu văn tiếng Việt chuẩn ngữ pháp thông qua bộ dịch thuật theo quy tắc.

2.2. TRÍCH XUẤT HÌNH THỂ VỚI MEDIAPIPE HOLISTIC

2.2.1. Giới thiệu

Trong các bài toán nhận diện thủ ngữ, nhận diện hành động hoặc phân tích cử chỉ con người, việc trích xuất đặc trưng trực tiếp từ ảnh hoặc video thường gặp nhiều khó khăn do ảnh hưởng của nền, ánh sáng, góc quay và khoảng cách đến camera. Để khắc phục vấn đề này, phương pháp trích xuất đặc trưng dựa trên các điểm mốc cơ thể (landmarks) được sử dụng rộng rãi.

Một trong những công cụ phổ biến hiện nay là MediaPipe Holistic, cho phép phát hiện đồng thời các điểm mốc của khuôn mặt, cơ thể và hai bàn tay trong thời gian thực. Các điểm mốc này được sử dụng như một biểu diễn hình học của cơ thể người, giúp giảm đáng kể kích thước dữ liệu đầu vào nhưng vẫn giữ được thông tin cần thiết cho việc nhận diện cử chỉ.



Hình 2. Giới thiệu Mediapipe Holistic

2.2.2. Khái niệm MediaPipe Holistic

MediaPipe Holistic là mô hình thị giác máy tính giải pháp tối ưu hóa luồng trích xuất đồng thời cấu trúc hình thể người (Human Topology) theo thời gian thực do Google phát triển. Thay vì xử lý từng vùng riêng lẻ một cách rời rạc, phiên bản Holistic kết hợp thông minh các mô hình mạng nơ-ron chuyên biệt (Pose, Hands và Face Mesh) vào một luồng tính toán đồng nhất. Việc này giúp mô hình tập trung vào hành động thay vì yếu tố không quan trọng như màu da, ánh sáng hoặc nền.

2.2.3. Các thành phần trích xuất đặc trưng chính

Dựa vào từng mục đích sinh (nhận diện khuôn mặt, nhận dạng dáng đi, cử chỉ, hoặc phân tích hành vi), các module tương ứng của MediaPipe được áp dụng:

MediaPipe Face Mesh (Trích xuất đặc trưng khuôn mặt)


Module này tạo ra một lưới hình học 3D của khuôn mặt người với 468 điểm mốc (landmarks).

- Đặc trưng tĩnh: Trích xuất các tỷ lệ khoảng cách, chiều dài/rộng giữa các điểm như mắt, mũi, miệng, viền hàm.
- Đặc trưng động: Phân tích các trạng thái cảm xúc, vị cơ, và cử động chớp mắt, nhướn mày.

MediaPipe Hands (Trích xuất đặc trưng bàn tay)

Cung cấp 21 điểm mốc trên mỗi bàn tay (từ gốc cổ tay, các khớp ngón tay đến đầu ngón tay).

- Hệ thống sử dụng bộ dữ liệu này để trích xuất hình học bàn tay, kích thước chiều dài/rộng ngón tay và cấu trúc lòng bàn tay.
- Ứng dụng hiệu quả trong việc tạo vùng quan tâm động (Dynamic ROI) cho sinh trắc học tĩnh mạch lòng bàn tay (Palm Vein) hoặc dấu vân tay.




Hình 3. Sơ đồ 21 điểm bàn tay của Mediapipe Hands

MediaPipe Pose (Trích xuất đặc trưng tư thế/dáng đi)

Cung cấp 33 điểm mốc trên toàn bộ cơ thể người, xác định các vị trí quan trọng như vai, khuỷu tay, hông, đầu gối và mắt cá chân.

- Giúp trích xuất thông tin sinh trắc học hành vi, đặc trưng dáng đi (Gait analysis) thông qua sự biến thiên góc của các khớp theo thời gian.



Hình 4. Sơ đồ 33 điểm Pose Landmarks của MediaPipe Pose

2.2.4. Ý tưởng của Mediapipe Holistic

Ý tưởng cốt lõi là thay vì sử dụng toàn bộ ảnh RGB, hệ thống chỉ giữ lại tọa độ các điểm mốc quan trọng.

Dữ liệu đầu vào

Video:

$$V = \{F_1, F_2, \dots, F_T\}$$

Trong đó:

- F_t là khung hình thứ t .
- T là số lượng frame.

Sau khi xử lý:

Mỗi frame được chuyển thành tập hợp landmark:

$$L_t = \{p_1, p_2, \dots, p_n\}$$

Trong đó:

$$p_i = (x_i, y_i, z_i)$$

Hoặc:

$$p_i = (x_i, y_i, z_i, v_i)$$

với:

- x, y : tọa độ chuẩn hóa trên ảnh.
- z : độ sâu tương đối.
- v : độ tin cậy (visibility).

Như vậy ảnh kích thước hàng trăm nghìn pixel được biểu diễn bằng vài trăm tọa độ số thực.

2.2.5. Hoạt động của Mediapipe Holistic

Giai đoạn 1 (Detection): Sử dụng mạng nơ-ron cực nhẹ BlazePose Detector để định vị nhanh vùng chứa thực thể người trong ảnh và thiết lập hộp giới hạn (Bounding Box) làm vùng quan tâm (ROI).

Giai đoạn 2 (Tracking): Từ vùng ROI tổng thể, mô hình thực hiện cắt ảnh (crop) và đưa vào các mạng hồi quy cục bộ chuyên biệt để định vị chính xác tọa độ 3D của các điểm neo (landmarks).

2.2.6. Vai trò trong đề tài nhận diện thủ ngữ tiếng Việt


Trong hệ thống nhận diện thủ ngữ tiếng Việt, MediaPipe Holistic đóng vai trò là bộ trích xuất đặc trưng đầu vào (Feature Extractor). Thay vì đưa video thô vào mô hình học sâu, mỗi khung hình được chuyển đổi thành tập hợp các tọa độ landmark. Chuỗi landmark này sau đó được đưa vào các mô hình học sâu như CNN, LSTM hoặc Transformer để học các mẫu chuyển động theo thời gian và thực hiện phân loại thủ ngữ.

Nhờ đó, hệ thống giảm đáng kể chi phí tính toán, tăng tốc độ huấn luyện và cải thiện khả năng nhận diện các động tác thủ ngữ trong điều kiện thực tế.

2.3. MẠNG TÍCH CHẬP ĐỒ THỊ KHÔNG-THỜI GIAN (ST-GCN)

2.3.1. Giới thiệu

Trong các bài toán nhận diện hành động và nhận diện ngôn ngữ ký hiệu, dữ liệu đầu vào thường được biểu diễn dưới dạng các điểm khớp xương (skeleton landmarks) thu được từ các công cụ như MediaPipe Holistic. Tuy nhiên, các mô hình CNN truyền thống được thiết kế cho dữ liệu dạng lưới (grid structure) như ảnh, trong khi dữ liệu skeleton có cấu trúc đồ thị (graph structure).



Hình 5. Giới thiệu về ST-GCN

Để giải quyết vấn đề này, Spatial Temporal Graph Convolutional Networks đã đề xuất mô hình ST-GCN (Spatial-Temporal Graph Convolutional Network), cho phép thực hiện phép tích chập trực tiếp trên dữ liệu đồ thị và đồng thời khai thác thông tin không gian và thời gian của chuỗi chuyển động.

ST-GCN hiện là một trong những mô hình nền tảng trong:

- Nhận diện hành động người.
- Nhận diện cử chỉ.
- Nhận diện ngôn ngữ ký hiệu.
- Phân tích chuyển động cơ thể.

2.3.2. Khái niệm

ST-GCN là mô hình học sâu kết hợp:

- Graph Convolution Network (GCN) để học quan hệ không gian giữa các khớp cơ thể.
- Temporal Convolution Network (TCN) để học sự thay đổi chuyển động theo thời gian.

Mạng tích chập đồ thị Không - Thời gian (Spatio-Temporal Graph Convolutional Networks - ST-GCN) là một bước tiến vượt bậc trong việc phân tích dữ liệu dạng khung xương người. Khác với các phương pháp CNN truyền thống coi chuỗi tọa độ là các vector phẳng, ST-GCN mô hình hóa cấu trúc xương cơ thể dưới dạng một đồ thị động không-thời gian $G = (V, E)$.

Đối với bài toán nhận diện ngôn ngữ ký hiệu, dữ liệu đầu vào thường là chuỗi các khung hình liên tiếp được trích xuất từ MediaPipe Holistic hoặc các hệ thống ước lượng tư thế khác. Mỗi khung hình chứa vị trí của các khớp tay, cơ thể và khuôn mặt theo thời gian. ST-GCN cho phép mô hình học được không chỉ mối quan hệ giữa các khớp trong cùng một thời điểm mà còn cả sự thay đổi chuyển động của chúng qua các khung hình liên tiếp.

2.3.3. Biểu diễn đồ thị không – thời gian

Một chuỗi khung xương được biểu diễn bởi đồ thị không-thời gian:

$$G = (V, E)$$

trong đó:

- V là tập các đỉnh (nodes), tương ứng với các khớp cơ thể.
- E là tập các cạnh (edges), bao gồm các cạnh không gian và cạnh thời gian.
- Tập đỉnh V : Chứa toàn bộ các khớp xương cơ thể qua các khung hình liên tiếp. Với N khớp xương và T khung hình, tập đỉnh được định nghĩa:

$$V = \{v_{ti} \mid t = 1, \dots, T; i = 1, \dots, N\}$$

- Tập đỉnh E: Gồm các liên kết vật lý không gian tự nhiên của cơ thể người trong cùng một khung hình (E_S) và các liên kết nối liền một khớp xương cụ thể qua các khung hình liên tiếp theo trục thời gian (E_T):

$$E_S = \{v_{ti}v_{tj} \mid (i, j) \in H\}$$

$$E_T = \{v_{ti}v_{(t+1)i} \mid t = 1, \dots, T - 1\}$$

Trong đó H là cấu trúc cây liên kết vật lý của xương người.

Do đó:

$$E = E_S \cup E_T$$

→ Nhờ cấu trúc này, ST-GCN có khả năng mô hình hóa đồng thời đặc trưng hình học của bộ xương và sự thay đổi động tác theo thời gian.

2.3.4. Phép tích chập đồ thị không gian (Spatial Graph Convolution)

Với một khung hình đơn lẻ, ma trận kề biểu diễn liên kết xương giữa N khớp là $A \in \mathbb{R}^{N \times N}$

Trong đó:

$$A_{ij} = \begin{cases} 1, & \text{nếu } i \text{ và } j \text{ được kết nối} \\ 0, & \text{ngược lại} \end{cases}$$

Để đảm bảo quá trình lan truyền thông tin ổn định và tránh hiện tượng bùng nổ hoặc tiêu biến gradient, ma trận kề được chuẩn hóa đối xứng:

$$\hat{A} = D^{-\frac{1}{2}}(A + I)D^{-\frac{1}{2}}$$

Trong đó:

- $I \in \mathbb{R}^{N \times N}$ là ma trận đơn vị, bổ sung các liên kết tự thân (Self-loop) của nút.
- D là ma trận bậc của đồ thị:

$$D_{ii} = \sum_j (A_{ij} + I_{ij})$$

Phép toán lan truyền tiến tích chập đồ thị không gian được định nghĩa bằng công thức:

$$F_{\text{out}} = \sigma(\hat{A}F_{\text{in}}W) + b$$

Với W là ma trận trọng số học tập được, b là bias và σ là hàm kích hoạt phi tuyến (thường sử dụng ReLU).

Thông qua phép toán này, mỗi khớp được cập nhật dựa trên thông tin của các khớp lân cận, giúp mô hình học được cấu trúc hình học của cơ thể người.

2.3.5. Phép tích chập đồ thị thời gian

Sau khi thu được đặc trưng không gian, ST-GCN tiếp tục áp dụng tích chập theo chiều thời gian nhằm khai thác sự thay đổi chuyển động giữa các khung hình liên tiếp.

Giả sử đầu ra từ tầng tích chập không gian là:

$$F_s \in \mathbb{R}^{C \times T \times N}$$

Phép tích chập thời gian sử dụng kernel kích thước K_t :

$$F_t = \text{Conv}_{temp}(F_s)$$

Quá trình này cho phép mô hình học được các mẫu chuyển động đặc trưng của hành động hoặc ký hiệu.

Ví dụ trong nhận diện ngôn ngữ ký hiệu, cùng một tư thế tay có thể mang ý nghĩa khác nhau tùy thuộc vào hướng và quỹ đạo chuyển động. Thành phần tích chập thời gian giúp ST-GCN phân biệt các trường hợp này bằng cách phân tích chuỗi chuyển động liên tiếp của các khớp.

2.3.6. Vai trò của ST-GCN trong bài toán nhận diện thủ ngữ tiếng Việt

Trong hệ thống nhận diện thủ ngữ tiếng Việt sử dụng MediaPipe Holistic, ST-GCN đóng vai trò là mô hình học đặc trưng không-thời gian. Sau khi MediaPipe

Holistic trích xuất các landmarks của cơ thể và hai bàn tay, các điểm này được tổ chức thành một đồ thị skeleton. ST-GCN thực hiện tích chập trên đồ thị để học mối quan hệ giữa các khớp trong từng khung hình (không gian) và sự thay đổi của chúng qua nhiều khung hình liên tiếp (thời gian).

Nhờ khả năng mô hình hóa đồng thời hình dạng bàn tay, tư thế cơ thể và quỹ đạo chuyển động, ST-GCN đặc biệt phù hợp với bài toán nhận diện thủ ngữ tiếng Việt, nơi ý nghĩa của một ký hiệu không chỉ phụ thuộc vào vị trí các ngón tay mà còn phụ thuộc mạnh mẽ vào diễn biến chuyển động theo thời gian. Trong nhiều nghiên cứu nhận diện ngôn ngữ ký hiệu, ST-GCN thường cho hiệu quả cao hơn các phương pháp chỉ sử dụng CNN hoặc MLP trên dữ liệu landmark do khai thác được đầy đủ bản chất đồ thị của bộ xương người.

2.4. CƠ CHẾ TỰ CHÚ Ý (SELF-ATTENTION) VÀ MẠNG TRANSFORMER ENCODER

2.4.1. Cơ chế tự chú ý (self-attention)

2.4.1.1. Giới thiệu

Cơ chế tự chú ý (Self-Attention) là thành phần cốt lõi của kiến trúc Transformer, được giới thiệu trong công trình nghiên cứu nổi tiếng “Attention Is All You Need” của Ashish Vaswani và cộng sự năm 2017. Self-Attention cho phép mô hình đánh giá mức độ quan trọng của từng phần tử trong một chuỗi đối với các phần tử còn lại, từ đó học được mối quan hệ phụ thuộc dài hạn mà không cần sử dụng các mạng tuần tự như RNN hay LSTM.

2.4.1.2. Ý tưởng cơ bản

Giả sử đầu vào là một chuỗi gồm n vector đặc trưng:

$$X = [x_1, x_2, \dots, x_n]$$

Cơ chế này cho phép mô hình xem xét mối quan hệ giữa một từ (hoặc một khung hình) với tất cả các từ (hoặc khung hình khác) trong cùng một chuỗi dữ liệu đầu vào, từ đó tự động gán trọng số biểu thị mức độ liên quan. Đối với mỗi vector biểu diễn đầu vào, mô hình sẽ chiếu nó vào ba không gian vector khác nhau để tạo ra ba vector mới: Query (Q - Truy vấn), Key (K - Khóa), và Value (V - Giá trị).

- Query: Đại diện cho token hoặc khung hình hiện tại đang được xem xét để tìm kiếm mối liên kết với các thành phần khác.

- Key: Đại diện cho nhãn hoặc đặc trưng của tất cả các token/khung hình trong chuỗi nhằm đối sánh với Query.
- Value: Chứa đựng thông tin nội dung thực tế của token/khung hình, sẽ được tổng hợp dựa trên trọng số chú ý thu được.

Các vector này được tính thông qua các ma trận trọng số học được:

$$Q = XW_Q$$

$$K = XW_K$$

$$V = XW_V$$

Trong đó:

- W_Q : Ma trận trọng số Query.
- W_K : Ma trận trọng số Key.
- W_V : Ma trận trọng số Value.

2.4.1.3. Cơ chế hoạt động

Mức độ liên quan giữa hai phần tử được xác định bằng tích vô hướng giữa Query và Key:

$$Score(Q, K) = QK^T$$

Sau đó thực hiện chuẩn hóa bằng hệ số:

$$\sqrt{d_k}$$

với d_k là số chiều của vector Key.

Điểm chú ý được tính:

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Quy trình gồm các bước:

1. Tính ma trận tương đồng QK^T .
2. Chia cho $\sqrt{d_k}$ để tránh giá trị quá lớn.
3. Áp dụng hàm Softmax để chuyển thành phân phối xác suất.

4. Nhân với ma trận V để tạo đầu ra cuối cùng.

2.4.1.4. Multi-Head Self-Attention

Thay vì chỉ sử dụng một cơ chế Attention, Transformer sử dụng nhiều “đầu chú ý” (Attention Heads).

Mỗi head học một kiểu quan hệ khác nhau:

- Head 1: Quan hệ vị trí gần nhau.
- Head 2: Quan hệ ngữ nghĩa.
- Head 3: Quan hệ chuyển động.
- Head 4: Quan hệ thời gian dài hạn.

Công thức:

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$$

Sau đó:

$$MultiHead(Q, K, V) = Concat(head_1, ..., head_h)W^O$$

Trong đó:

- h : số lượng head.
- W^O : ma trận trọng số đầu ra.

Ưu điểm:

- Học được nhiều loại đặc trưng đồng thời.
- Nắm bắt phụ thuộc xa tốt hơn RNN/LSTM.
- Có khả năng xử lý song song.

2.4.2. Mạng Transformer Encoder

2.4.2.1. Giới thiệu

Transformer Encoder là thành phần mã hóa của kiến trúc Transformer. Nhiệm vụ của Encoder là chuyển đổi chuỗi đầu vào thành biểu diễn đặc trưng có ngữ nghĩa cao để phục vụ cho bài toán phân loại hoặc dự đoán.

2.4.2.2. Kiến trúc Transformer Encoder

Một Encoder Layer gồm hai thành phần chính: Multi-Head Self-Attention và Feed Forward Network

(1) Multi-Head Self-Attention: Thực hiện học mối quan hệ giữa các phần tử trong chuỗi.

Đầu vào:

$$X \in \mathbb{R}^{n \times d}$$

Đầu ra:

$$Z = \text{MultiHead}(X)$$

(2) Feed Forward Network (FFN): Sau lớp Attention, mỗi vector được đưa qua mạng MLP hai tầng:

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Trong đó:

- Lớp đầu mở rộng số chiều.
- Hàm ReLU tạo tính phi tuyến.
- Lớp thứ hai đưa dữ liệu về kích thước ban đầu.

2.4.2.3. Residual Connection

Để tránh mất thông tin khi mạng sâu lên, Transformer sử dụng kết nối tắt (Residual Connection):

$$Y = X + \text{Sublayer}(X)$$

Lợi ích:

- Tránh hiện tượng tiêu biến gradient.
- Tăng tốc độ hội tụ.
- Giữ lại thông tin gốc.

2.4.2.4. Layer Normalization

Sau mỗi Residual Connection sẽ thực hiện chuẩn hóa:

$$\text{LayerNorm}(x)$$

Mục đích:

- Ổn định phân phối dữ liệu.

- Giúp quá trình huấn luyện nhanh hơn.
- Tăng khả năng tổng quát hóa.

2.4.2.5. Positional Encoding

Do Transformer không có cấu trúc tuần tự như RNN nên cần bổ sung thông tin vị trí.

Positional Encoding được tính theo hàm sin và cos:

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d}}\right)$$

Vai trò:

- Giúp mô hình biết thứ tự xuất hiện của các phần tử.
- Bảo toàn thông tin thời gian trong chuỗi.

Trong nhận diện thủ ngữ, Positional Encoding giúp mô hình phân biệt:

- Thứ tự chuyển động của bàn tay.
- Sự thay đổi tư thế theo thời gian.
- Các động tác có hình dạng giống nhau nhưng trình tự khác nhau

2.4.3. Vai trò của Self-Attention và Transformer Encoder trong đề tài Nhận diện Thủ ngữ Tiếng Việt

Trong bài toán nhận diện thủ ngữ tiếng Việt, Self-Attention là cơ chế cốt lõi giúp mô hình đánh giá mức độ quan trọng của từng frame đối với việc nhận diện ký hiệu. Dựa trên cơ chế này, Transformer Encoder xây dựng các biểu diễn đặc trưng có khả năng nắm bắt quan hệ dài hạn và ngữ cảnh toàn cục của toàn bộ chuỗi chuyển động.

Khi kết hợp với MediaPipe Holistic để trích xuất landmarks và ST-GCN để học đặc trưng không-thời gian của bộ xương người, Transformer Encoder giúp hệ thống khai thác hiệu quả các phụ thuộc theo thời gian, từ đó nâng cao độ chính xác trong nhận diện thủ ngữ tiếng Việt, đặc biệt đối với các ký hiệu có cấu trúc chuyển động phức tạp và kéo dài nhiều khung hình.

2.5. RULE-BASED NLP TRANSLATOR (BỘ DỊCH NGÔN NGỮ TỰ NHIÊN DỰA TRÊN LUẬT)

2.5.1. Giới thiệu

Trong các hệ thống xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP), một trong những nhiệm vụ quan trọng là chuyển đổi thông tin từ dạng biểu diễn này sang dạng biểu diễn khác. Trước khi các mô hình học sâu và Transformer trở nên phổ biến, các hệ thống dịch máy chủ yếu được xây dựng dựa trên các tập luật ngôn ngữ học được thiết kế thủ công.

Rule-based NLP Translator sử dụng tập hợp các quy tắc ngữ pháp, từ điển và luật chuyển đổi ngôn ngữ để thực hiện việc dịch hoặc chuyển đổi câu từ ngôn ngữ nguồn sang ngôn ngữ đích. Trong các hệ thống nhận diện thủ ngữ, phương pháp này thường được sử dụng để chuyển đổi kết quả nhận dạng từ nhân thủ ngữ sang câu tiếng Việt có nghĩa hoặc chuẩn hóa chuỗi từ nhận dạng thành văn bản tự nhiên.

2.5.2. Khái niệm

Rule-based NLP Translator là hệ thống dịch dựa trên:

- Từ điển song ngữ hoặc từ điển ánh xạ.
- Các quy tắc ngữ pháp.
- Các luật chuyển đổi cú pháp.
- Các quy tắc ngữ nghĩa được xây dựng thủ công.

Thay vì học từ dữ liệu như các mô hình học máy, hệ thống hoạt động dựa trên tập luật được chuyên gia ngôn ngữ xây dựng trước.

Pipeline tổng quát: Ngôn ngữ nguồn → Phân tích ngôn ngữ → Áp dụng luật chuyển đổi → Sinh câu đích → Ngôn ngữ đích.

2.5.3. Ý tưởng hoạt động

Giả sử hệ thống nhận diện thủ ngữ dự đoán được chuỗi: [tôi] [gặp] [vui].

Trong ngôn ngữ ký hiệu, thứ tự từ đôi khi khác với tiếng Việt tự nhiên.

Rule-based Translator sẽ áp dụng các luật: [tôi] [gặp] [vui] → “tôi rất vui khi gặp được bạn”.

Như vậy hệ thống không chỉ ghép từ đơn thuần mà còn điều chỉnh theo quy tắc ngôn ngữ.

2.5.4. Vai trò trong đề tài nhận diện thủ ngữ tiếng Việt

Trong đề tài nhận diện thủ ngữ tiếng Việt, Rule-based NLP Translator đóng vai trò là bộ chuyển đổi ngôn ngữ ở tầng cuối của hệ thống. Sau khi mô hình học

sâu (MediaPipe Holistic, ST-GCN và Transformer Encoder) nhận diện được các nhãn thủ ngữ, bộ dịch dựa trên luật sẽ ánh xạ các nhãn này sang từ tiếng Việt tương ứng, đồng thời áp dụng các quy tắc ngữ pháp và cú pháp để tạo thành câu hoàn chỉnh, tự nhiên và dễ hiểu. Phương pháp này đặc biệt phù hợp với các bộ dữ liệu thủ ngữ có số lượng từ vựng và cấu trúc câu còn hạn chế, giúp nâng cao chất lượng đầu ra mà không yêu cầu thêm dữ liệu huấn luyện lớn cho các mô hình ngôn ngữ phức tạp.

CHƯƠNG 3: PHƯƠNG PHÁP ĐỀ XUẤT TRIỂN KHAI

3.1. TIỀN XỬ LÝ DỮ LIỆU VÀ CHUẨN HÓA KHÔNG GIAN

Quy trình tiền xử lý dữ liệu được thiết kế chặt chẽ nhằm làm sạch và chuẩn hóa tối đa đặc trưng khung xương đầu vào:

3.1.1. Trích xuất đặc trưng và điền khuyết

Hệ thống trích xuất và giữ lại hệ tọa độ không gian ba chiều (x, y, z) của 67 điểm khớp cốt lõi:

- Tư thế cơ thể (Pose Landmarks): Trích xuất 25 điểm neo đầu tiên (từ vai, khuỷu tay, cổ tay cho đến các điểm thân người), bỏ qua các điểm chân dưới không liên quan đến ký hiệu thủ ngữ.
- Bàn tay trái (Left Hand Landmarks): Trích xuất đầy đủ 21 điểm neo mô tả chi tiết các khớp ngón tay và lòng bàn tay.
- Bàn tay phải (Right Hand Landmarks): Trích xuất đầy đủ 21 điểm neo mô tả chi tiết bàn tay phải.

Với những khung hình bị mất dấu do che khuất ngẫu nhiên, hệ thống sử dụng thuật toán điền khuyết hướng tiến/lùi (ffill/bfill) và lấp đầy các khoảng trống trống bằng giá trị mặc định để đảm bảo chuỗi không chứa giá trị NaN gây lỗi tính toán lan truyền mạng nơ-ron:

```
def fill_missing_keypoints(sequence: np.ndarray) -> np.ndarray:
    T, V, C = sequence.shape
    df = pd.DataFrame(sequence.reshape(T, -1))
    df = df.ffill(axis=0).bfill(axis=0).fillna(0.0)
    return df.to_numpy(dtype=np.float32).reshape(T, V, C)
```

Hình 6. Hàm lấp đầy khoảng trống bằng thuật toán ffill/bfill

3.1.2. Cắt bỏ khung hình tĩnh (Motion Trimming):

Để loại bỏ phần video dư thừa khi người thực hiện chưa bắt đầu ra ký hiệu, hệ thống tính toán đạo hàm tổng động năng dịch chuyển của cả hai bàn tay trên chuỗi thời gian:

$$\text{Diff}(t) = \sum_{v \in \text{Hands}} \sum_{c \in \{x, y, z\}} |P(t+1, v, c) - P(t, v, c)|$$

Sau đó áp dụng bộ lọc trung bình trượt (Moving Average) với kích thước cửa sổ bằng 5 để làm mịn tín hiệu. Ngưỡng cắt động được tính bằng $\text{Threshold} = 0.3 \times \text{Mean}(\text{Smoothed})$. Hệ thống chỉ giữ lại các khung hình nằm trong khoảng tích cực từ khung hình chủ động đầu tiên đến khung hình chủ động cuối cùng (có bù thêm biên độ an toàn 2 frame đầu và 3 frame cuối).

3.1.3. Chuẩn hóa không gian tọa độ (Spatial Normalization)

Để loại bỏ sự sai lệch về vóc dáng cơ thể và khoảng cách đứng xa/gần của người đại diện đối với camera, hệ thống thực hiện phép tịnh tiến gốc tọa độ về điểm trung tâm nối giữa hai vai (Left Shoulder - khớp số 11 và Right Shoulder - khớp số 12):

$$\text{Anchor}(t) = \frac{P(t, 11) + P(t, 12)}{2}$$

Khoảng cách chuẩn hóa $W(t)$ được tính bằng độ rộng vật lý giữa hai vai:

$$W(t) = \|P(t, 11) - P(t, 12)\|_2$$

Tọa độ chuẩn hóa của mọi khớp v tại thời điểm t tuân theo công thức dịch chuyển và co giãn:

$$P_{\text{normalized}}(t, v) = \frac{P(t, v) - \text{Anchor}(t)}{W(t)}$$

3.2. CÁC KỸ THUẬT TĂNG CƯỜNG DỮ LIỆU

Để nâng cao khả năng tổng quát hóa của mô hình VSTGCN trên tập dữ liệu nhỏ và chống Overfitting mạnh mẽ, hệ thống tích hợp chuỗi 6 kỹ thuật tăng cường:

- **Temporal Crop (Cắt trích thời gian):** Cắt ngẫu nhiên một phân đoạn chuỗi chiếm từ 80% đến 100% trục thời gian gốc, sau đó áp dụng phép nội suy tuyến tính (Linear Interpolation) để đưa chuỗi về đúng độ dài đích chuẩn 60 frame. Kỹ thuật này giúp mô hình nhận diện tốt ký hiệu bất kể tốc độ ra động tác nhanh hay chậm.
- **Time Warp (Biến dạng nhịp điệu):** Thiết lập một hệ lưới thời gian phi tuyến tính bằng cách lấy ngẫu nhiên 6 điểm neo trên dòng thời gian và làm lệch vị trí của chúng một khoảng tối đa $\pm 15\%$ tổng thời lượng chuỗi. Sau đó nội suy lại lưới thời gian để tạo ra biến thể động tác có nhịp điệu

không đều (đoạn đầu nhanh, đoạn sau chậm), mô phỏng thực tế thói quen của người dùng.

- **Random Gaussian Noise (Nhiều ngẫu nhiên):** Cộng thêm một lượng nhiễu trắng nhỏ tuân theo phân phối chuẩn $N(0, 0.005^2)$ vào tọa độ của các khớp chuyển động, giúp mô phỏng hiện tượng run nhẹ của tay người biểu diễn.
- **Global Scaling (Thu phóng không gian):** Nhân toàn bộ hệ tọa độ khớp của chuỗi với một hệ số tỉ lệ ngẫu nhiên $\alpha \in [0.88, 1.12]$, mô phỏng sự biến đổi khoảng cách đứng của người dùng đối với camera.
- **Spatial Jitter phân vùng (Nhiều phân vùng):** Áp dụng mức nhiễu khác nhau dựa trên tầm quan trọng của các bộ phận cơ thể. Thân người (khớp 0-24) ít chuyển động nên nhận mức nhiễu cực nhỏ $N(0, 0.003^2)$, trong khi các ngón tay (khớp 25-66) nhận mức nhiễu lớn hơn $N(0, 0.008^2)$ giúp mô hình nhảy bén và tổng quát hóa tốt hơn với cấu hình tay chi tiết.
- **Joint Dropout (Ẩn khớp ngẫu nhiên):** Zero hóa hoàn toàn dữ liệu tọa độ của 1 đến 2 khớp ngón tay ngẫu nhiên trong suốt chuỗi thời gian, mô phỏng hiện tượng camera bị mất dấu hoặc bị che khuất ngón tay trong thực tế.

3.3. HỆ THỐNG TRÍCH XUẤT ĐẶC TRƯNG ĐA LUỒNG (MULTI-STREAM FEATURE ENGINEERING)

Sau khi chuỗi tọa độ 3D thô $P \in \mathbb{R}^{T \times N \times 3}$ được làm sạch và tăng cường, hệ thống tự động tính toán mở rộng không gian đặc trưng lên 9 kênh dữ liệu, chia thành 3 luồng đặc trưng cốt lõi:

- **Luồng Khớp (Joint Stream - 3 kênh):** Giữ nguyên tọa độ chuẩn hóa ba chiều (x, y, z) của từng khớp xương tại mỗi khung hình t:

$$J(t, v) = P(t, v)$$

- **Luồng Vận tốc (Velocity Stream - 3 kênh):** Tính toán hiệu số tọa độ giữa khung hình liền sau và khung hình hiện tại nhằm bám sát vận tốc và hướng chuyển động động của khớp:

$$V(t, v) = P(t + 1, v) - P(t, v), \quad \forall t \in [1, T - 1]$$

Với khung hình cuối cùng, vận tốc được sao chép từ khung hình trước đó: $V(T, v) = V(T-1, v)$.

- **Luồng Hướng Xương (Bone Stream - 3 kênh):** Tính toán hiệu số tọa độ giữa khớp hiện tại và khớp cha (Parents Node) được định nghĩa theo cây cấu trúc xương người:

$$B(t, v) = P(t, v) - P(t, \text{Parent}(v))$$

Chỉ số khớp cha của từng khớp trong tổng số 67 khớp được cấu hình tĩnh thông qua mảng PARENTS trong mã nguồn. Luồng này giúp mô phỏng chính xác độ dài liên kết vật lý và hướng chỉ của từng đoạn xương cơ thể.

3.4. XÂY DỰNG KIẾN TRÚC MÔ HÌNH VSTGCN

Kiến trúc mô hình VSTGCN được trình bày trong bảng dưới đây, mô tả các lớp và thông số từng thành phần trong mạng.

Tên Tầng	Input Shape	Output Shape	Trọng Số/Hệ Số	Hàm Kích Hoạt
Data Input	[B, 9, 60, 67]	[B, 60, 67, 9]	permute(0, 2, 3, 1)	None
ST-GCN Block 1	[B, 60, 67, 9]	[B, 60, 67, 256]	- GCN: Linear(9, 256) - TCN: Conv2d(256, 256, k=(3,1), p=(1,0)) - Residual: Conv2d(9, 256, k=1)	ReLU + Dropout (0.3)
ST-GCN Block 2	[B, 60, 67, 256]	[B, 60, 67, 256]	- GCN: Linear(256, 256) - TCN: Conv2d(256, 256, k=(3,1), p=(1,0)) - Residual: Identity()	ReLU + Dropout (0.3)

ST-GCN Block 3	[B, 60, 67, 256]	[B, 60, 67, 256]	- GCN : Linear(256, 256) - TCN : Conv2d(256, 256, k=(3,1), p=(1,0)) - Residual : Identity()	ReLU + Dropout (0.3)
Space Flatten	[B, 60, 67, 256]	[B, 60, 17152]	reshape(B, T, V * C)	None
Spatial Projection	[B, 60, 17152]	[B, 60, 256]	nn.Linear(17152, 256) + nn.LayerNorm(256)	None
Positional Embed	[B, 60, 256]	[B, 60, 256]	max_len=60, d_model=256	None
Transformer Enc	[B, 60, 256]	[B, 60, 256]	num_layers=2, nhead=4, dim_feedforward=1024	GELU + Dropout (0.3)
Temporal Pooling	[B, 60, 256]	[B, 256]	mean(dim=1)	None
Classifier FC	[B, 256]	[B, 538]	nn.Linear(256, 538)	Softmax (đầu ra)

Bảng 1. Mô tả các lớp và thông số của từng thành phần trong mạng

Giải thích:

- Layer 0: Data Input (Khởi tạo và Hoán vị Tensor)
 - + Kích thước dòng chảy (Vào $\rightarrow$ Ra): $[B, 9, 60, 67] \rightarrow [B, 60, 67, 9]$.
 - + Chức năng vật lý và thuật toán: Tiếp nhận Batch dữ liệu thô chứa 9 kênh đặc trưng không-thời gian (Joint, Velocity, Bone) của 67 khớp xương chạy suốt 60 khung hình. Thực hiện phép toán biến đổi hoán vị hệ trục $\text{permute}(0, 2, 3, 1)$ để chuyển đổi Tensor từ cấu trúc chuẩn ảnh màu sang cấu trúc không gian đồ thị động.
 - + Cơ chế & Công thức toán học: Dữ liệu ban đầu được định nghĩa là $X \in \mathbb{R}^{B \times C \times T \times V}$, phép hoán vị ánh xạ các chiều chỉ mục:

$$X_{\text{permuted}}[b, t, v, c] = X[b, c, t, v] \quad \forall b \in B, c \in C, t \in T, v \in V$$

➔ Đưa chiều thời gian (T=60) lên vị trí thứ hai giúp tối ưu hóa xử lý tuần lập trên bộ nhớ đệm, đặt chiều khớp (V=67) cạnh chiều đặc trưng để sẵn sàng cho phép nhân đồ thị.

- Layer 1: ST-GCN Block 1 (Tích chập Không-Thời gian cấp thấp)
 - + Kích thước dòng chảy (Vào → Ra): $[B, 60, 67, 9] \rightarrow [B, 60, 67, 256]$
 - + Chức năng vật lý & thuật toán: Trích xuất các liên kết đặc trưng hình học cơ bản của xương người (như quan hệ giữa các khớp đốt tay kề nhau) và theo dõi vận tốc tức thời cục bộ. Thực hiện nâng số kênh đặc trưng của khớp từ 9 kênh thô lên 256 kênh ẩn cấp cao.
 - + Cơ chế & Công thức toán học: Đầu vào $X \in \mathbb{R}^{B \times 60 \times 67 \times 9}$ được đưa đồng thời qua hai luồng:
 1. Luồng học đồ thị và TCN:

$$X_{\text{gcn}} = \text{ReLU} \left(\hat{A} \cdot (XW_{\text{gcn}_1}) + b_{\text{gcn}_1} \right) \in \mathbb{R}^{B \times 60 \times 67 \times 256}$$

$$X_{\text{tcn}} = \text{Dropout} \left(\text{ReLU} \left(\text{BatchNorm2d} \left(\text{Conv2D}(X_{\text{gcn}}, \text{kernel_size} = (3, 1), \text{padding} = (1, 0)) \right) \right), p = 0.3 \right)$$

2. Luồng kết nối tắt (Residual): Chiều tuyến tính 9 kênh thô lên 256 kênh ẩn thông qua hạt nhân tích chập Conv2D 1×1 :

$$X_{\text{res}} = \text{BatchNorm2d} \left(\text{Conv2D}(X, \text{kernel_size} = (1, 1)) \right) \in \mathbb{R}^{B \times 256 \times 60 \times 67}$$

➔ Cộng chập hai luồng: $X_{\text{out}} = X_{\text{tcn}} + X_{\text{res}}$. Điều này giúp ngăn chặn sự tiêu biến gradient khi đột ngột mở rộng dung lượng kênh của Tensor.

- Layer 2: ST-GCN Block 2 (Tích chập Không-Thời gian cấp trung)
 - + Kích thước dòng chảy (Vào → Ra): $[B, 60, 67, 256] \rightarrow [B, 60, 67, 256]$
 - + Chức năng vật lý & thuật toán: Tinh lọc các đặc trưng khớp cấp thấp và bắt đầu mô hình hóa quan hệ động học kết hợp giữa các bộ phận trên cơ thể (Ví dụ: Sự chuyển động tương đối của hai bàn tay so với khớp vai và khuôn mặt).
 - + Cơ chế & Công thức toán học: Kích thước kênh vào và ra hoàn toàn đồng bộ ($256 \rightarrow 256$). Luồng tích chập không gian GCN và thời gian TCN được lặp lại tương tự Layer 1. Tuy nhiên, luồng kết nối tắt ở

đây được đơn giản hóa tối đa bằng một phép toán đồng nhất (Identity Mapping):

$$X_{\text{res}} = X_{\text{in}}$$

$$X_{\text{out}_2} = X_{\text{tcn}} + X_{\text{in}} \in \mathbb{R}^{B \times 60 \times 67 \times 256}$$

➔ Giúp duy trì ổn định dòng thông tin xuyên suốt mô hình mà không cần bổ sung thêm tham số tích chập phụ trợ.

- Layer 3: ST-GCN Block 3 (Tích chập Không-Thời gian cấp cao)
 - + Kích thước dòng chảy (Vào $\rightarrow$ Ra): $[B, 60, 67, 256] \rightarrow [B, 60, 67, 256]$
 - + Chức năng vật lý & thuật toán: Trích xuất các thông tin ngữ nghĩa chuyển động phức tạp nhất và có tầm ảnh hưởng toàn cục trên cơ thể (Ví dụ: Quỹ đạo xoay tròn của cổ tay kết hợp cùng trạng thái cúi đầu hay đưa người ra phía trước).
 - + Cơ chế & Công thức toán học: Đây là tầng tích chập đồ thị cuối cùng. Áp dụng tương tự Layer 2 với kết nối tắt Identity:

$$X_{\text{out}_3} = \text{TCN}(\text{GCN}(X_{\text{out}_2})) + X_{\text{out}_2} \in \mathbb{R}^{B \times 60 \times 67 \times 256}$$

➔ Đầu ra của tầng này chứa đựng toàn bộ các biểu diễn đặc trưng không-thời gian cục bộ tinh túy nhất của cơ thể múa thủ ngữ.

- Layer 4: Space Flatten (Trải phẳng Không gian Khớp)
 - + Kích thước dòng chảy (Vào $\rightarrow$ Ra): $[B, 60, 67, 256] \rightarrow [B, 60, 17152]$
 - + Chức năng vật lý & thuật toán: Chuyển đổi dữ liệu từ không gian đồ thị 4 chiều động sang dạng ma trận chuỗi thời gian 3 chiều phẳng.
 - + Cơ chế & Công thức toán học: Sử dụng hàm $x.\text{reshape}(B, T, V * C)$ để trải phẳng toàn bộ 67 đỉnh khớp xương và 256 kênh đặc trưng của mỗi khớp thành một vector đặc trưng duy nhất có kích thước không lồ 17152 (67×256):

$$X_{\text{flat}}[b, t, d] = X_{\text{out}_3}[b, t, v, c] \quad \text{với } d = v \cdot 256 + c$$

➔ Lớp này dọn đường để thực hiện phép chiếu bảo tồn không gian ngón tay tinh tế ở lớp tiếp theo.

- Layer 5: Spatial Projection (Phép chiếu nhúng bảo tồn ngón tay SOTA)
 - + Kích thước dòng chảy (Vào $\rightarrow$ Ra): $[B, 60, 17152] \rightarrow [B, 60, 256]$.
 - + Chức năng vật lý & thuật toán: Khắc phục triệt để nhược điểm làm mất đặc trưng ngón tay của phép Pooling trung bình truyền thống. Thực hiện nén thông minh vector đặc trưng từ 17152 về 256 chiều, giữ nguyên vẹn thông tin tương quan không gian của các đầu ngón tay.
 - + Cơ chế & Công thức toán học: Đầu vào được chiếu qua một mạng tuyến tính Fully Connected và chuẩn hóa bằng LayerNorm:

$$X_{\text{proj}}(t) = \text{LayerNorm}(X_{\text{flat}}(t) \cdot W_{\text{proj}} + b_{\text{proj}}) \in \mathbb{R}^{256}$$

- ➔ Thông qua quá trình lan truyền ngược, ma trận trọng số $W_{\text{proj}} \in \mathbb{R}^{17152 \times 256}$ sẽ tự động học cách gán hệ số ưu tiên cực cao cho các khớp ngón tay linh hoạt (đầu ngón trỏ, ngón cái) và giảm hệ số ảnh hưởng của các khớp tĩnh (vai, hông), tạo ra không gian biểu diễn hoàn hảo nhất cho thủ ngữ.
- Layer 6: Positional Encoding (Mã hóa Vị trí lượng giác)
 - + Kích thước dòng chảy (Vào $\rightarrow$ Ra): $[B, 60, 256] \rightarrow [B, 60, 256]$
 - + Chức năng vật lý & thuật toán: Cung cấp thông tin thứ tự thời gian của các frame ảnh cho Transformer Encoder (vốn xử lý dữ liệu song song và không có tính tuần tự tự nhiên).
 - + Cơ chế & Công thức toán học: Cộng trực tiếp ma trận PE lượng giác tĩnh vào Tensor đầu vào:

$$X_{\text{pos}}[b, t, c] = X_{\text{proj}}[b, t, c] + PE[1, t, c]$$

- ➔ Đảm bảo mô hình phân biệt được hướng chuyển động của tay theo trục thời gian (Ví dụ: Đưa tay từ trái sang phải mang ngữ nghĩa hoàn toàn khác với đưa tay từ phải sang trái).
- Layer 7: Transformer Encoder (Học ngữ cảnh chuỗi dài toàn cục)
 - + Kích thước dòng chảy (Vào $\rightarrow$ Ra): $[B, 60, 256] \rightarrow [B, 60, 256]$
 - + Chức năng vật lý & thuật toán: Trọng tâm phân tích ngữ cảnh của video ký hiệu. Cho phép mọi khung hình tương tác trực tiếp với nhau không giới hạn khoảng cách thời gian để học nhịp điệu chuyển động động toàn câu.

- + Cơ chế & Công thức toán học: Dữ liệu đi qua 2 lớp Transformer Encoder Layer. Tại mỗi lớp, cơ chế Multi-Head Attention sử dụng 4 đầu chú ý độc lập

$$X_{\text{attn}} = \text{MultiHeadAttention}(Q, K, V) + X_{\text{pos}}$$

$$X_{\text{trans}} = \text{LayerNorm}(\text{FeedForward}(\text{LayerNorm}(X_{\text{attn}})) + X_{\text{attn}})$$

➔ Mỗi đầu chú ý tự học cách bám bắt một khía cạnh chuyển động khác nhau (Ví dụ: Đầu 1 tập trung vào nhịp tăng tốc, Đầu 2 tập trung vào cấu hình ngón tay lúc đứng im), giúp mô hình nhạy bén tối đa với các biến dạng tốc độ múa tay của người khiếm thính.

- Layer 8: Temporal Mean Pooling (Gom tụ Thời gian)
 - + Kích thước dòng chảy (Vào → Ra): $[B, 60, 256] \rightarrow [B, 256]$
 - + Chức năng vật lý & thuật toán: Gom tụ toàn bộ dòng thời gian của chuỗi video (60 frames) về một vector đặc trưng phẳng tĩnh duy nhất mang đầy đủ ngữ nghĩa không-thời gian toàn cục của video ký hiệu.
 - + Cơ chế & Công thức toán học: Tính trung bình cộng các vector nhúng dọc theo chiều thời gian T:

$$X_{\text{global}} = \frac{1}{60} \sum_{t=1}^{60} X_{\text{trans}}[b, t, :] \in \mathbb{R}^{256}$$

➔ Phép toán này giúp nén thông tin chuỗi về dạng nén gọn nhẹ nhất mà không làm mất mát ngữ cảnh dài đã được học bởi Transformer.

- Layer 9: Classifier FC (Tầng phân loại nhân tuyến tính)
 - + Kích thước dòng chảy (Vào → Ra): $[B, 256] \rightarrow [B, 538]$
 - + Chức năng vật lý & thuật toán: Thực hiện ánh xạ vector đặc trưng toàn cục của video về không gian điểm số xác suất của 538 lớp nhãn ngôn ngữ ký hiệu.
 - + Cơ chế & Công thức toán học: Sử dụng phép chiếu tuyến tính để sinh ra Logits thô, sau đó nạp vào hàm kích hoạt Softmax để xuất ra phân phối xác suất lớp:

$$\text{Logits} = X_{\text{global}} \cdot W_{\text{fc}} + b_{\text{fc}} \in \mathbb{R}^{538}$$

$$\hat{y}_c = \frac{e^{\text{Logits}_c}}{\sum_{j=1}^{538} e^{\text{Logits}_j}} \quad \forall c \in [0, 537]$$

→ Chỉ số của lớp có giá trị xác suất $\hat{y}_c$ cao nhất chính là từ khóa (Gloss) được hệ thống dự đoán và hiển thị ra màn hình.

3.5. BỘ DỊCH THUẬT CÚ PHÁP THEO QUY TẮC NGOẠI TUYẾN (RULE-BASED NLP TRANSLATOR)

Sau khi mô hình VSTGCN nhận diện thành công chuỗi từ khóa thô (Gloss), các từ này được đưa vào bộ đệm của mô-đun dịch thuật theo quy tắc. Chúng em thiết lập các bộ quy tắc biểu thức chính quy (Regex) và từ điển ánh xạ thủ công để tái cấu trúc câu tiếng Việt chuẩn hóa.

- Khớp mẫu cụm từ (Pattern Matching): Tự động phát hiện các từ đơn xuất hiện liên nhau trong bộ đệm và gom chúng lại thành cụm từ mang ngữ nghĩa trang trọng. Ví dụ:

{“xin chào”, “mọi người”} → “Xin chào mọi người!”

- Quy tắc trật tự thời gian (Temporal Restructuring): Người khiếm thính có thói quen ra ký hiệu chỉ mốc thời gian ở cuối câu. Bộ dịch thuật sử dụng Regex để bắt các trạng từ thời gian (như “hôm qua”, “ngày mai”, “tuần trước”, “tuần sau”) ở cuối câu, tự động cắt và đưa chúng về đầu câu, đồng thời bổ sung thêm các phó từ chỉ phân thì tương ứng (“đã”, “sẽ”) vào trước động từ chính:

{“cảm ơn”, “mọi người”, “lắng nghe”} → “Cảm ơn mọi người đã lắng nghe”

- Quy tắc câu hỏi nghi vấn (Interrogative Restructuring): Nhận diện các từ khóa thô mang ý nghĩa nghi vấn xuất hiện cuối câu (như “không”, “chưa”, “gì”, “bao giờ”), tự động chèn thêm trợ động từ tương ứng vào vị trí phù hợp trong câu và chuyển đổi dấu kết thúc thành dấu hỏi chấm:

{“bạn”, “tên”, “là gì”} → “Tên của bạn là gì?”

CHƯƠNG 4: THỰC NGHIỆM VÀ XÂY DỰNG WEBSITE

Mục tiêu của chương này là trình bày chi tiết quá trình thực nghiệm nhằm xác minh tính đúng đắn và hiệu quả của phương pháp nhận diện câu từ các ký hiệu đơn lẻ trong ngôn ngữ ký hiệu Việt Nam (VSL) đã đề xuất. Ngoài ra, nhóm nghiên cứu cũng triển khai xây dựng mô hình thành ứng dụng web đơn giản để đánh giá khả năng áp dụng trong thực tế.

4.1. MÔI TRƯỜNG VÀ CÔNG CỤ THỰC NGHIỆM

Đề tài được thực nghiệm trên máy tính cá nhân và google colab.

Máy tính cá nhân:


- Hệ điều hành: Window 11
- CPU: Intel Core i5-1035G1
- GPU: tích hợp với CPU – Intel UHD Graphics
- RAM: 16GB

Phần mềm huấn luyện mô hình được thực hiện trên Google Colab với cấu hình:

- Hệ điều hành: Ubuntu
- CPU: Intel Xeon 2.20Hz
- RAM: 13GB
- GPU: NVIDIA T4
- VRAM: 16GB

4.2. THU THẬP DỮ LIỆU

Dữ liệu ngôn ngữ ký hiệu có sẵn không nhiều và thường không công khai đầy đủ. Do đó, nhóm tiến hành tự thu thập video ký hiệu từ trang web QIPEDC – Từ điển Ngôn ngữ Ký Hiệu Việt Nam trực tuyến – thuộc Bộ GD&ĐT. Trang web cung cấp hàng nghìn video ngắn, mỗi video biểu diễn một từ/cụm từ ký hiệu cụ thể. Các video đều đi kèm thông tin mô tả văn bản, thuận lợi cho việc gán nhãn.



Hình 7. Trang web QIPEDC về tài liệu ngôn ngữ ký hiệu

Nhận thấy dữ liệu thu thập từ trang web không có những ký hiệu cần thiết để ghép nối thành câu hoàn chỉnh. Mỗi thành viên nhóm đã tự quay thêm video và cắt các đoạn video tìm thấy trên các trang mạng xã hội để thu thập thêm. Nhóm đã thu thập hơn 500 video bao gồm nhiều video có ký tự giống nhau nhưng người quay, góc quay khác nhau.



Hình 8. Video thu thập từ nhóm

Mỗi video được đặt tên theo ID cố định và lưu vào thư mục Dataset/Videos. Thông tin nhãn (label) gồm ID, tên file và từ/cụm từ được lưu trong Dataset/Text/label.csv

Ví dụ dòng dữ liệu trong label.csv:

```
ID, VIDEO, LABEL
1,A0001.mp4,xin chào
```

2,A0002.mp4,bạn

Tổng cộng thu thập hơn 5000 video tương ứng với hơn 1000 từ/cụm từ khác nhau.


4.3. THAM SỐ HUẤN LUYỆN

Tham Số Thiết Lập	Phương Pháp Đề Xuất Đồ Án	Ý Nghĩa Kỹ Thuật & Tác Dụng Thực Tế
Phân chia dữ liệu (Data Split)	80% Train / 10% Val / 10% test (Stratified Split)	Stratified bảo toàn phân bố nhãn đều, tránh crash do thiếu mẫu trong tập validation, test.
Bộ cân bằng động (Dynamic Balancer)	Có áp dụng (Bù mẫu tự động)	Tự động nhân bản các class yếu bằng 6 kỹ thuật tăng cường để đạt cân bằng.
Kích thước mẻ học (Batch Size)	32	Batch size 32 cân bằng hoàn hảo giữa tính ổn định khi cập nhật độ dốc gradient và dung lượng bộ nhớ VRAM của GPU NVIDIA T4 trên tập mẫu nhỏ.
Thuật toán tối ưu	AdamW (L2 Regularization mạnh)	AdamW tách biệt phần Weight Decay ($1e-4$) giúp cập nhật gradient ổn định, chống co giãn trọng số quá mức.
Hàm mất mát (Loss Function)	Cross-Entropy + Label Smoothing (0.05)	Làm mềm nhãn cứng giúp giảm độ tự tin thái quá, tăng tính tổng quát hóa trên tập dữ liệu nhỏ.

Điều phối tốc độ học (Scheduler)	OneCycleLR (Warm-up & Cosine Decay)	Tăng dần LR lên cực đại 10^{-3} ở 30% chặng đầu rồi giảm dần về cực tiểu giúp tránh bẫy cực tiểu địa phương.
Số lượng vòng lặp (Epochs)	80	Định nghĩa một 80 lần huấn luyện hoàn chỉnh.
Dừng sớm (Early Stopping Patience)	12 Epochs (min_delta = $1e-4$)	Tránh dừng sớm oan uổng do tập val nhỏ thường biến động nhẹ trước khi hội tụ tối ưu.

Bảng 2. Mô tả tham số huấn luyện của mô hình

4.4. KẾT QUẢ THỰC NGHIỆM



Hình 9. Biểu đồ loss và top-accuracy

Biểu đồ bên trái: Loss qua các Epochs

- Đường xanh (Train Loss): độ lỗi trên tập huấn luyện.
- Đường đỏ (Validation Loss): độ lỗi trên tập validation.

* Nhận xét:

- Epoch đầu:
 - + Train Loss ≈ 5.7
 - + Val Loss ≈ 5.3
- Sau khoảng 10 epoch:
 - + Loss giảm rất mạnh $\rightarrow$ mô hình học được các đặc trưng quan trọng.

- Cuối quá trình:

+ Train Loss ≈ 0.85

+ Val Loss ≈ 1.60

➔ Mô hình học được tốt. Tuy có khoảng cách giữa train loss và val loss nhưng không quá nghiêm trọng.

Biểu đồ bên phải: Accuracy trên Validation

Có hai chỉ số:

- Val Top-1 Accuracy (màu xanh lá): Dự đoán đúng ngay ở lựa chọn đầu tiên.

+ Cuối training: Top-1 Accuracy $\approx 80\%$

+ Ví dụ: Label thật: “Xin chào”

Model dự đoán:

1. Xin chào

2. Cảm ơn

3. Tạm biệt

➔ Top 1 đúng.

- Val Top-5 Accuracy (màu tím): Label thật nằm trong 5 dự đoán có xác suất cao nhất.

+ Cuối training: Top-5 Accuracy $\approx 88\%$

+ Ví dụ: Label thật: "Xin chào"

Model dự đoán:

1. Cảm ơn

2. Xin chào

3. Tạm biệt

4. Ngủ ngon

5. Vui

➔ Top 5 đúng

Đánh giá tổng thể:

Chỉ số	Giá trị cuối
Train Loss	~0.85
Val Loss	~1.60
Val Top-1	~80%
Val Top-5	~88%

Bảng 3. Bảng đánh giá loss và top-accuracy

Đánh giá:

- Mô hình hội tụ tốt.
- Validation Accuracy khá cao.
- Chưa xuất hiện overfitting nghiêm trọng


4.5. TRIỂN KHAI WEBSITE

- Tầng Giao diện & Thu thập (Presentation & Capture Layer): Chạy trực tiếp trên trình duyệt Web phía Client. Sử dụng API tiêu chuẩn của HTML5 (`navigator.mediaDevices.getUserMedia`) để mở luồng camera RGB phân giải cao (1280×720) của Webcam và gắn vào một thẻ `<video>` ẩn để xử lý.
- Tầng Giao tiếp song công thời gian thực (Real-time Communication Layer): Dùng kết nối WebSockets song công thông qua giao thức Socket.IO. Luồng Client liên tục chụp màn hình Video, nén ảnh định dạng JPEG chất lượng 75% để giảm tải băng thông và gửi lên Server dưới dạng chuỗi nhị phân Base64.
- Tầng Phân tích & Trích xuất khung xương (Engine Processing Layer): Được điều phối bởi máy chủ Backend chạy Python Flask kết hợp thư viện Flask-SocketIO. Tiếp nhận chuỗi Base64, giải mã nhanh thành ma trận ảnh số thực OpenCV và đẩy vào thực thể SLREngine. Tại đây, MediaPipe Holistic được khởi chạy để trích xuất 67 khớp cốt lõi, đồng thời vẽ Overlay khung xương thời gian thực nếu Client bật tùy chọn Skeleton Toggle.
- Tầng Suy diễn & Dịch thuật Ngữ pháp (Inference & NLP Layer): Mô hình PyTorch VSTGCN nạp bộ trọng số đã huấn luyện tối ưu nhất (`best_model.pth`) trực tiếp lên GPU/CPU. SLREngine sử dụng cấu trúc

hàng đợi trượt (sliding window) để thu thập đủ 60 frames tọa độ khớp động, suy luận ra Gloss tương ứng với độ chính xác cao. Cuối cùng, kết quả thô được nạp vào bộ dịch ngữ pháp theo quy tắc NLPTranslator để trả về câu hoàn chỉnh dạng chữ viết cho Client.


Dịch vụ Backend được thiết kế để xử lý bất đồng bộ các yêu cầu từ Client đồng thời kiểm soát nghiêm ngặt tài nguyên phần cứng (được hiện thực hóa trong tệp app.py và slr_engine.py):

- Giao diện nhận dạng ký hiệu đơn lẻ sau đó dịch thành câu văn bản.




Hình 10. Giao diện nhận diện ký tự đơn lẻ dịch thành câu qua webcam

- + Từ nhận diện hiển thị nhãn (label) mà mô hình vừa nhận dạng được từ chuỗi động tác tay hiện tại.: [“Xin chào”, “mọi người”]
- + Confidence (xác suất dự đoán của mô hình) là độ tự tin nhận diện khi đạt đủ sự tự tin thì nó sẽ hiện ra ký tự người dùng đã ký hiệu. Ở đây mô hình phải tự tin trên 0.5 mới đủ ngưỡng để xuất ra kết quả.
- + Câu dịch là câu tiếng Việt được tạo ra sau khi nhận dạng.
- + Bộ đệm là số lượng từ được lưu trong bộ nhớ tạm.
- + Tiến trình nhận diện hiển thị số frame đã thu thập được để tạo thành một chuỗi đầu vào cho mô hình. Mô hình chỉ dự đoán khi 60/60 frames
- Người dùng có thể tham khảo 1 số video từ vựng ngôn ngữ ký hiệu bằng cách chọn tab từ điển ngôn ngữ ký hiệu của trang web.



Hình 11. Giao diện cho phép người dùng tra từ điển ký hiệu xem video

- Người dùng có thể tải lên 1 video về người đang ký hiệu ngôn ngữ dạng câu.



Hình 12. Giao diện cho phép người dùng tải video lên và nhận diện câu

Đánh giá hiệu năng nhận diện từ trang web:

Chỉ số hiệu năng (Metrics)	Kết quả đo đặc trưng bình	Nhận xét dưới góc độ kỹ thuật
Độ trễ trích xuất MediaPipe	~4.2 ms	Thực thi mượt mà trên CPU đa nhân thông thường.
Độ trễ suy diễn VSTGCN (Inference)	~12.5 ms	Phép toán tối ưu giúp dòng dữ liệu chạy siêu tốc.
Độ trễ xử lý NLP Translator	< 0.1 ms	Thực thi trực tiếp do thuật toán Regex tối ưu hóa cực tốt.

Tổng độ trễ chu kỳ (End-to-End Latency)	~18.0 ms	Hoàn toàn đáp ứng thời gian thực vượt trội (real-time).
Tốc độ khung hình hệ thống (FPS)	25 - 30 FPS	Chuỗi hiển thị hình ảnh vô cùng mượt mà, không giật lag.

Bảng 4. Bảng đánh giá hiệu năng của web khi nhận diện câu

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. CÁC KẾT QUẢ ĐẠT ĐƯỢC CỦA ĐỒ ÁN

Trải qua quá trình nghiên cứu lý thuyết chuyên sâu kết hợp cùng triển khai kỹ thuật thực nghiệm bài bản, đồ án đã hoàn thành xuất sắc toàn bộ các mục tiêu đặt ra:

- Xây dựng Pipeline xử lý dữ liệu động tối ưu: Thiết kế thành công chuỗi 6 kỹ thuật tăng cường không-thời gian động kết hợp bộ điều phối Dynamic Balancer. Giải quyết triệt để vấn đề thiếu hụt dữ liệu và mất cân bằng lớp mẫu học tập (Imbalanced Data) của ngôn ngữ ký hiệu Việt Nam trên tập dữ liệu nhỏ.
- Đóng góp cải tiến kiến trúc VSTGCN đột phá: Đề xuất và ứng dụng thành công tầng chiếu không gian Spatial Embedding Projection bảo tồn nguyên vẹn cấu trúc khớp ngón tay chi tiết, mở đường cho mạng Transformer Encoder học sâu sắc các đặc trưng chuỗi động thời gian dài của thủ ngữ.
- Triển khai ứng dụng Web thời gian thực thực tế: Phát triển thành công hệ thống Website giao tiếp duplex siêu tốc thông qua Socket.IO. Tích hợp bộ dịch cú pháp theo quy tắc ngoại tuyến (Rule-based NLP) hoạt động offline 100% cực kỳ ổn định, kết hợp cơ chế tự động kết câu thông minh khi hạ tay (Auto-Finalize) mang lại trải nghiệm tương tác tự nhiên, nhân văn cho người khiếm thính.

2. CÁC HẠN CHẾ CÒN TỒN TẠI

Dù đạt được những thông số kỹ thuật ấn tượng, hệ thống vẫn có một số mặt hạn chế cần khắc phục:

- Độ nhạy môi trường: MediaPipe Holistic hoạt động kém ổn định hơn trong điều kiện thiếu sáng hoặc người dùng mặc quần áo quá rộng che khuất các khớp khuỷu tay/vai, làm ảnh hưởng gián tiếp đến chất lượng tọa độ đầu vào của mô hình.
- Giới hạn phạm vi câu ký hiệu động liên tục: Bộ dịch Rule-based NLP hiện tại hoạt động cực tốt trong phạm vi 538 từ vựng đã lập trình quy tắc, tuy nhiên sẽ gặp khó khăn khi xử lý các câu ký hiệu động liên tục quá dài có cấu trúc rẽ nhánh ngữ pháp quá phức tạp.

3. HƯỚNG NGHIÊN CỨU VÀ PHÁT TRIỂN TRONG TƯƠNG LAI

Để đưa sản phẩm nghiên cứu của đề án ứng dụng sâu rộng và thực tiễn đời sống xã hội, chúng tôi định hướng các nội dung phát triển tiếp theo:

- Mở rộng mô hình nhận diện thủ ngữ liên tục (Continuous SLR): Nghiên cứu tích hợp các thuật toán học chuỗi sâu hơn kết hợp hàm lỗi CTC (Connectionist Temporal Classification) để nhận diện trực tiếp chuỗi video dài chứa nhiều từ ký hiệu liên tiếp mà không bắt buộc người dùng phải hạ tay để ngắt câu.
- Nâng cấp bộ dịch thuật ngữ pháp bằng LLMs siêu nhẹ chạy Offline: Thay thế bộ quy tắc Rule-based NLP bằng các dòng mô hình ngôn ngữ lớn nội bộ có kích thước tối giản (như Qwen-0.5B hoặc Llama-1B chạy offline qua Ollama) để nâng cao khả năng dịch cú pháp câu thông minh, trôi chảy và tự nhiên như người bản xứ.
- Đóng gói ứng dụng di động đa nền tảng: Chuyển đổi mã nguồn Web sang dạng ứng dụng di động di động (Mobile App) chạy trực tiếp trên Android và iOS sử dụng framework React Native hoặc Flutter, biến camera di động cầm tay thành một chiếc "kính lúp công nghệ" phiên dịch ngôn ngữ ký hiệu bỏ túi cho cộng đồng người khiếm thính mọi lúc, mọi nơi.

TÀI LIỆU THAM KHẢO

- [1] Thomas N. Kipf, Max Welling, Semi-Supervised Classification with Graph Convolutional Networks, International Conference on Learning Representations (ICLR), 2017.
- [2] Sijie Yan, Yuanjun Xiong, Dahua Lin, Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition, AAAI Conference on Artificial Intelligence, 2018.
- [3] Ian Goodfellow, Yoshua Bengio, Aaron Courville, Deep Learning, MIT Press, 2016.
- [4] Aurélien Géron, Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow, 3rd Edition, O'Reilly Media, 2022.
- [5] Joseph Redmon, Ali Farhadi, YOLOv3: An Incremental Improvement, arXiv preprint arXiv:1804.02767, 2018.
- [6] Google, MediaPipe Framework Documentation, <https://developers.google.com/mediapipe>, truy cập ngày 15/05/2026.
- [7] TensorFlow Team, TensorFlow Documentation, <https://www.tensorflow.org>, truy cập ngày 15/05/2026.
- [8] François Chollet, Deep Learning with Python, 2nd Edition, Manning Publications, 2021.
- [9] David A. Forsyth, Jean Ponce, Computer Vision: A Modern Approach, 2nd Edition, Pearson, 2012.
- [10] Nguyễn Đức Thiện, Giáo trình Trí tuệ nhân tạo, Nhà xuất bản Giáo dục Việt Nam, 2022.
- [11] Hiệp hội Người Khiếm thính Việt Nam, Tài liệu giới thiệu Ngôn ngữ ký hiệu Việt Nam, 2024.